

第四课
深度学习与目标检测

复旦大学可信具身智能研究院

陈智能

2026-9-28

课程概要

传统目标检测方法：人脸实时检测及意义

两阶段检测方法：符合人类思维，速度慢，精度高

一阶段检测方法：可控的暴力美学，速度快，精度受限

卷积新进展：有创造力的建模，快速和准确兼具

基于Transformer的检测方法：更高、更强

目标检测的新趋势：实时、开放与可提示

激动人心的20年，从不可用到可用，到好用，再到超越人类

Part 1

传统目标检测方法

目标检测任务

目标检测：在给定的图片中精确找到物体所在位置，并标注出物体的类别。

问题难点：物体的尺寸变化范围很大，摆放物体的角度，姿态不定，而且可以出现在图片的任何地方，更何况物体还可以是多个类别。

分类



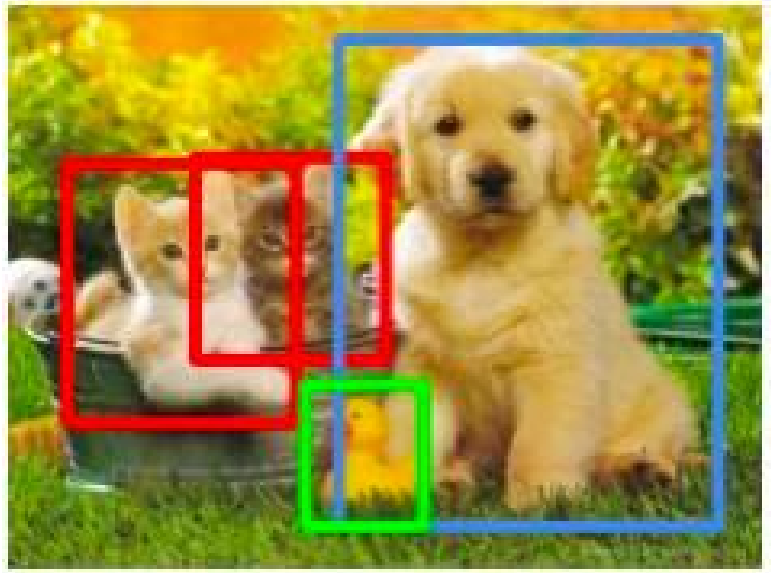
Cat

定位



Cat

目标检测

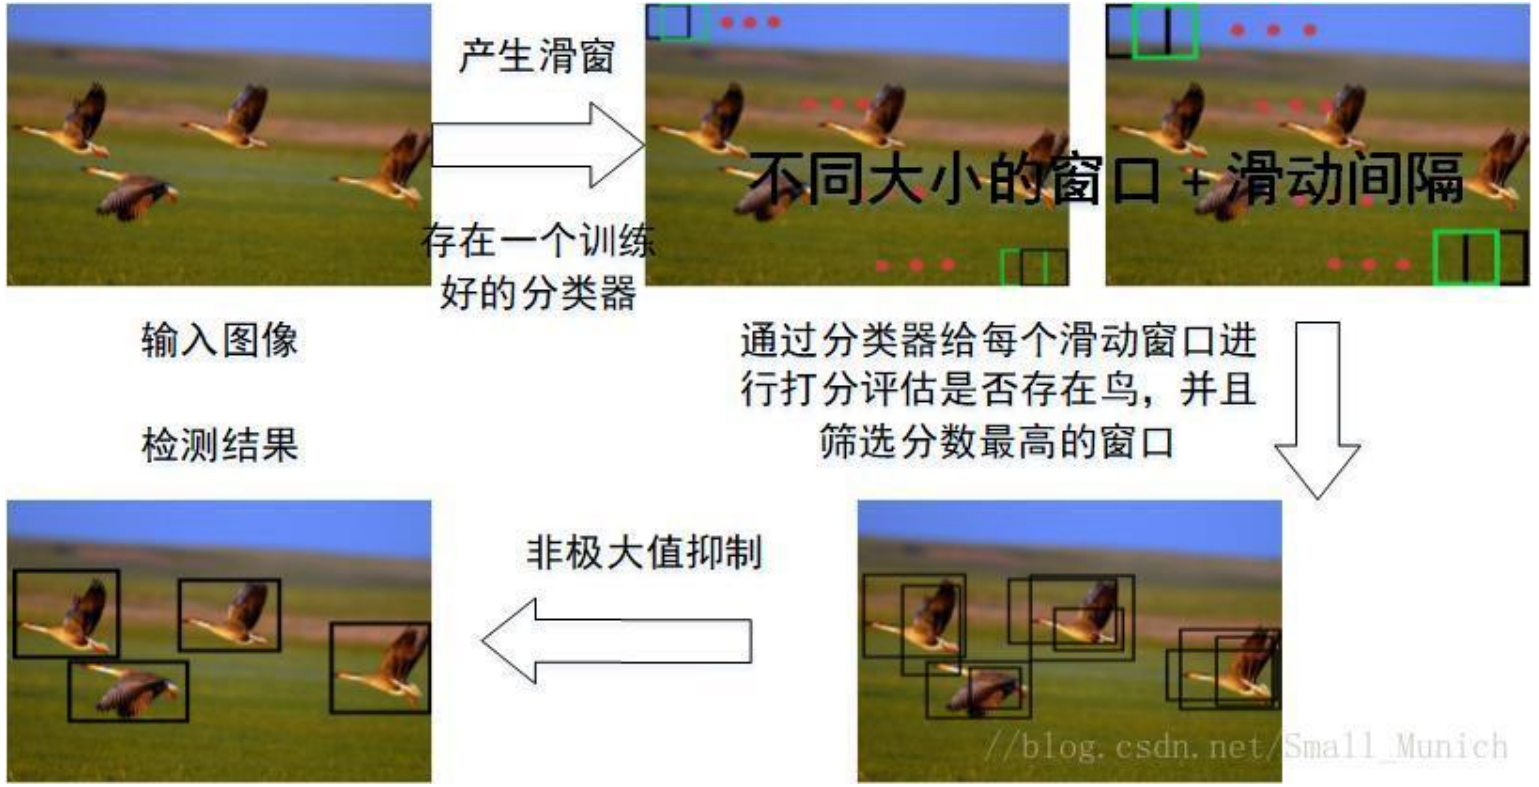


Cat dog duck

传统目标检测方法

1、基于滑动窗的目标检测

目标可以以任意尺寸出现在任意位置　　滑动窗口检测



在一张图像上检测某个特定目标（比如鸟）

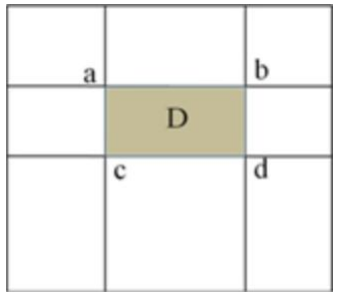
- ✓ 涉及对数千个不同位置和尺寸的窗口逐一进行分类判别
- ✓ 消耗大量计算资源
- ✓ 难以实现实时检测

传统目标检测方法

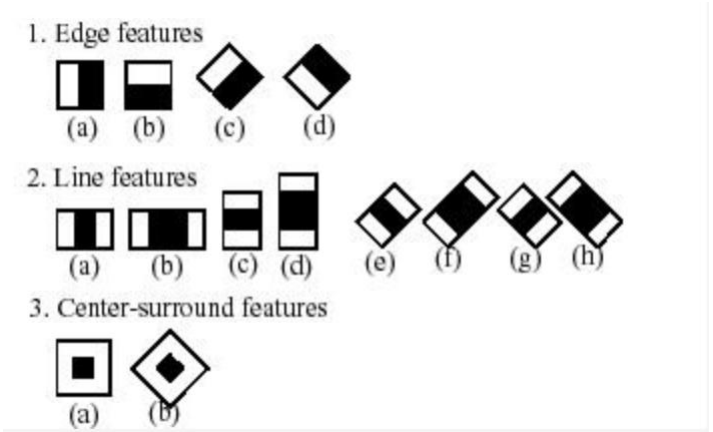
2、VJ Detector：实时目标检测（人脸）

第一个实时的图像人脸检测器

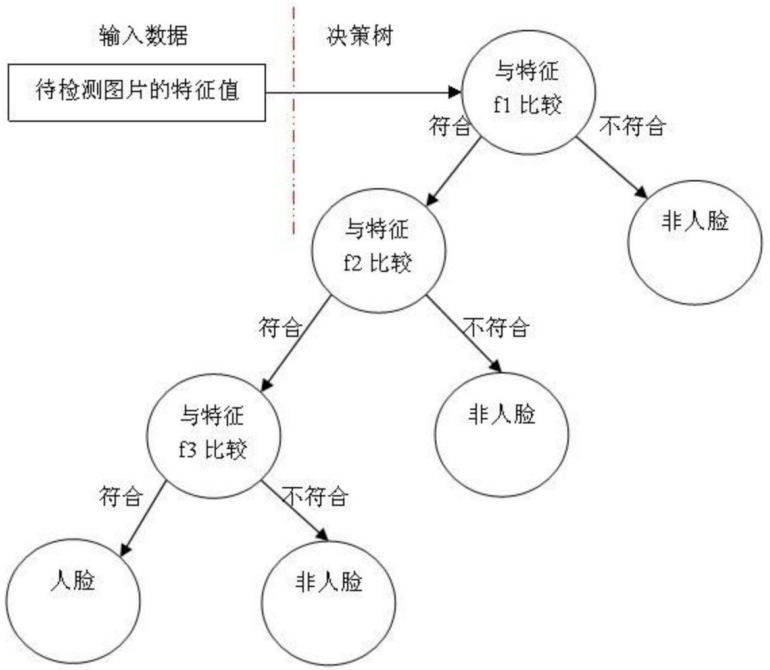
- ✓ 将图像表示为积分图像，快速计算haar-like特征
- ✓ Adaboost算法：基于多个haar-like弱分类器构建强分类器
- ✓ 采用cascade级联多个强分类器，快速过滤大量不相关窗口



在积分图像上快速
计算区域像素值之和



多种haar-like特征



adaboost+cascade人脸检测框架，前面的
分类器运算简单，越往后越复杂

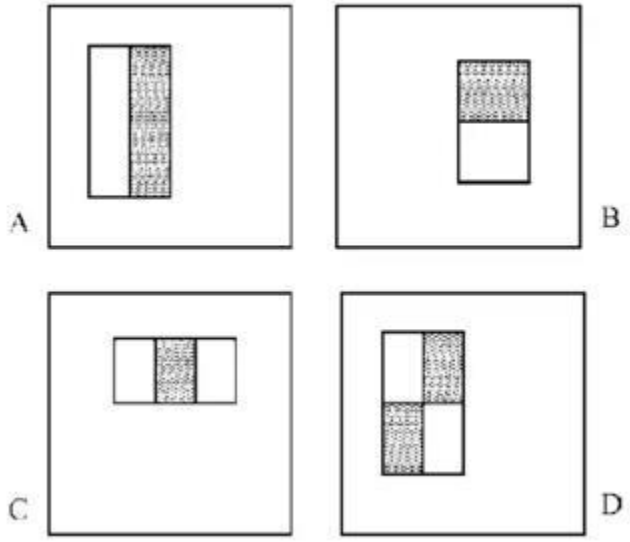
D=val(d)-val(c)-val(b)+val(a)

Paul Viola, Michael J. Jones, Robust Real-Time Face Detection, IJCV 2004

传统目标检测方法

2、VJ Detector：实时目标检测（人脸）

积分图



Haar-like特征

1	2	2	4	1
3	4	1	5	2
2	3	3	2	4
4	1	5	4	6
6	3	2	1	3



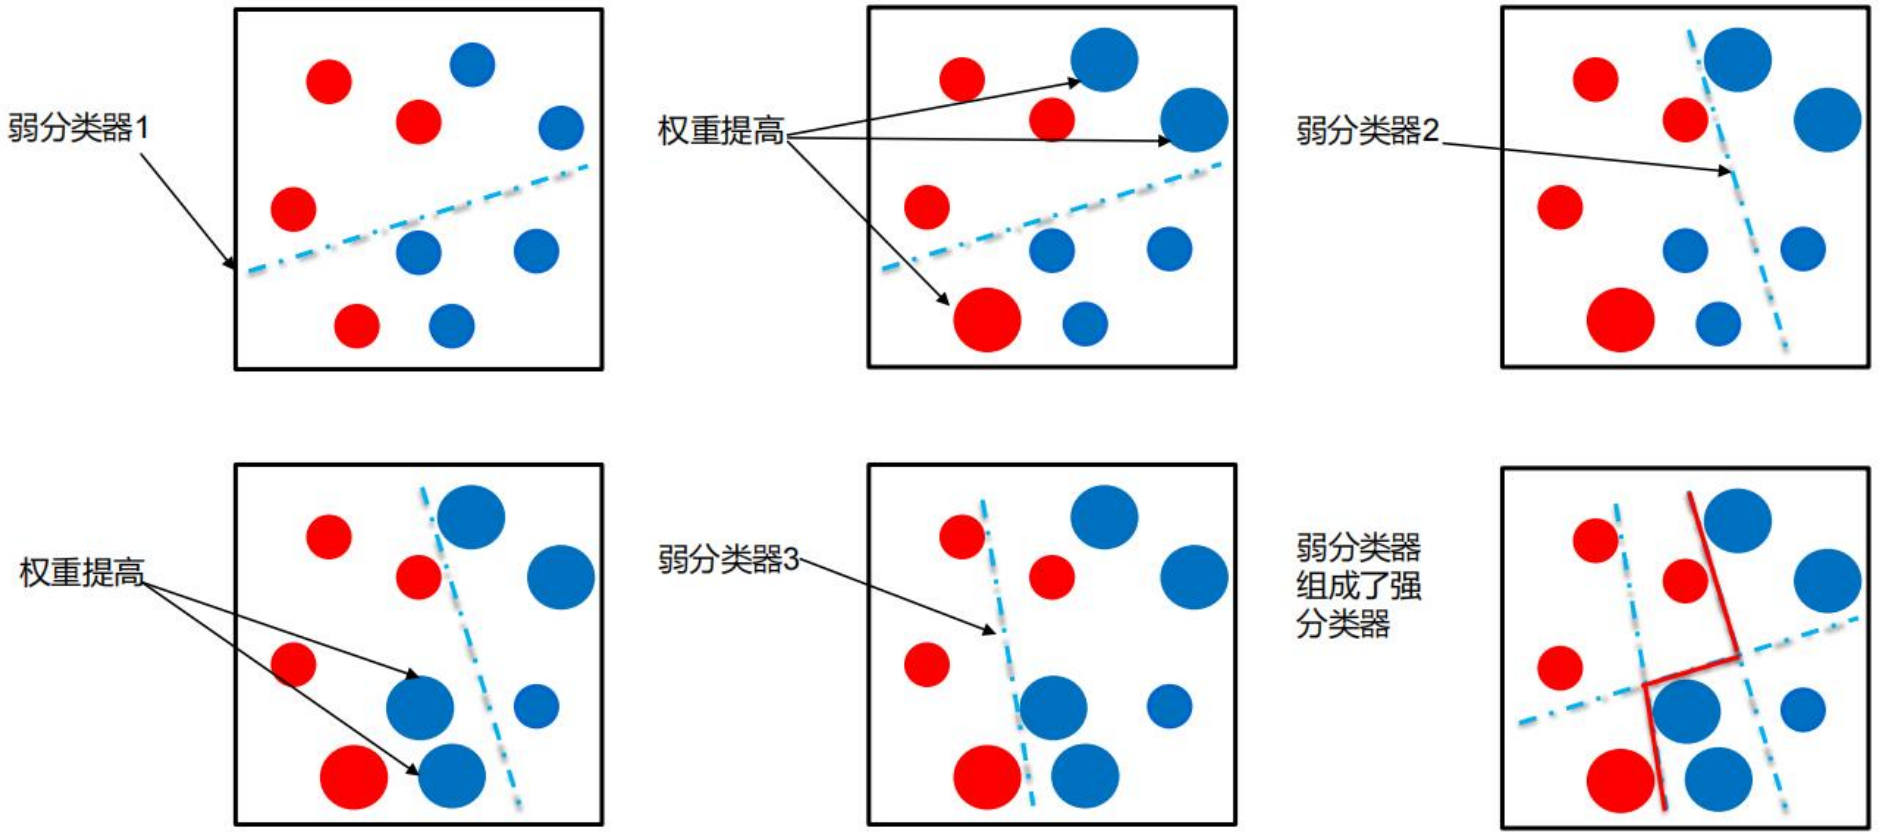
1	3	5	9	10
4	10	13	22	25
6	15	21	32	39
10	20	31	46	59
16	29	42	58	74

在积分图像上快速
计算区域像素值之和

传统目标检测方法

2、VJ Detector：实时目标检测（人脸）

Adaboost算法



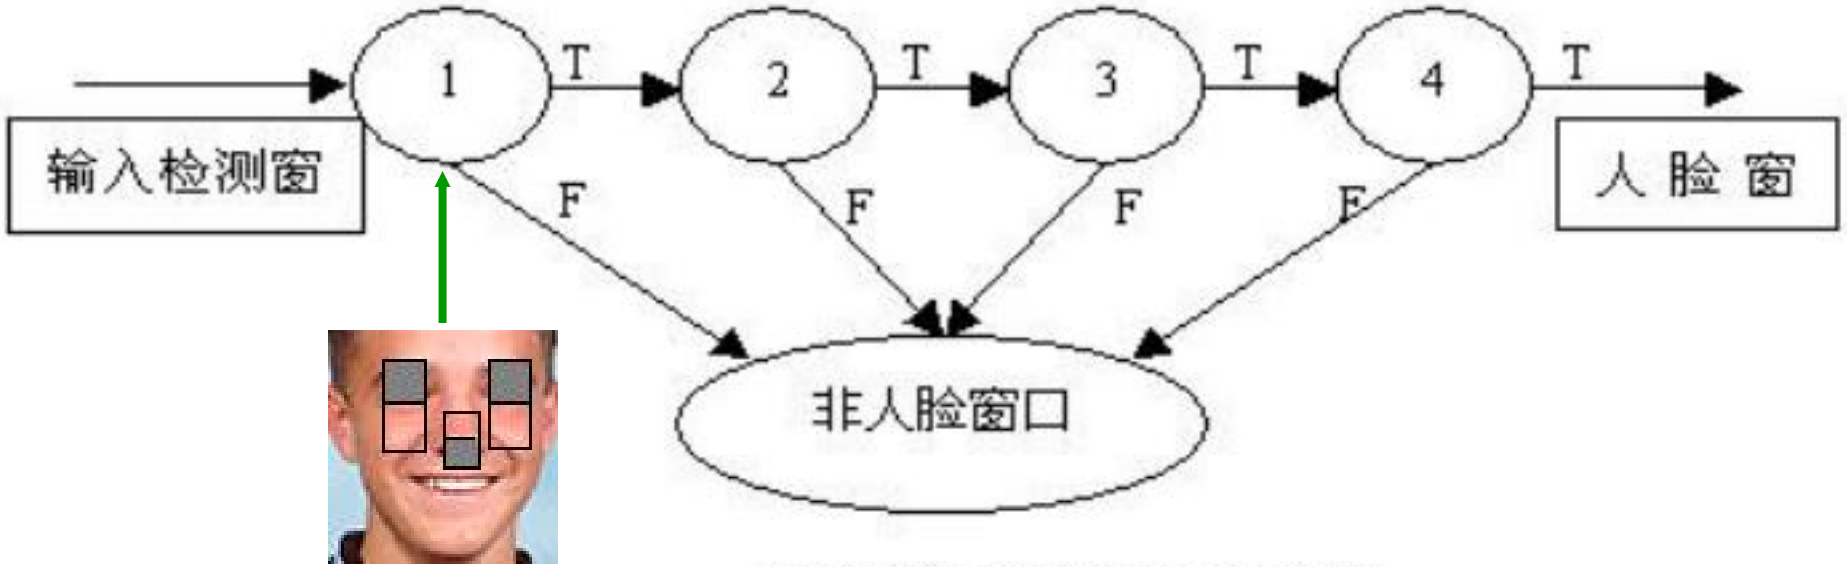
传统目标检测方法

2、VJ Detector：实时目标检测（人脸）

Cascade级联框架

大量候选窗口可以利用非常少量的特征（简单快速的分类器）就可以排除是人脸的可能性！

只有极少数需要大量的特征（更复杂的更慢的分类器来判别是否人脸）



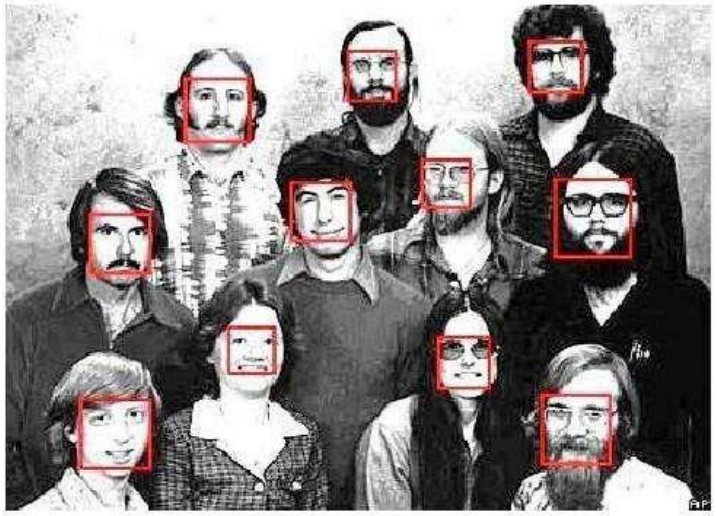
分级加速结构示意图[VI01]

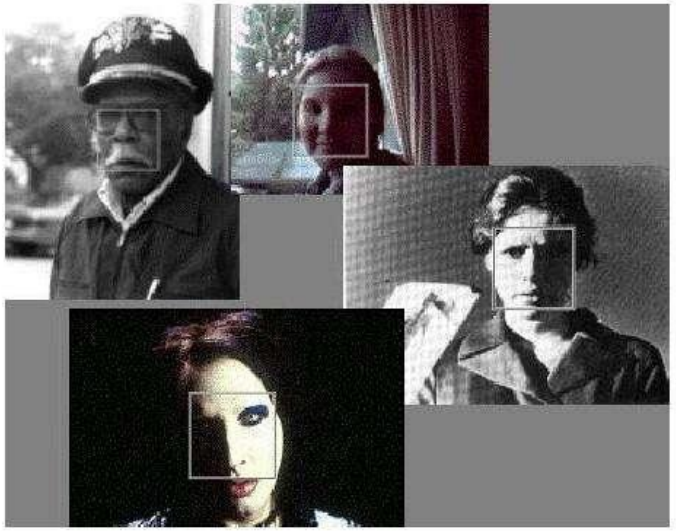
传统目标检测方法

数码相机的故事

Face detection

检测结果示例









科研的意义

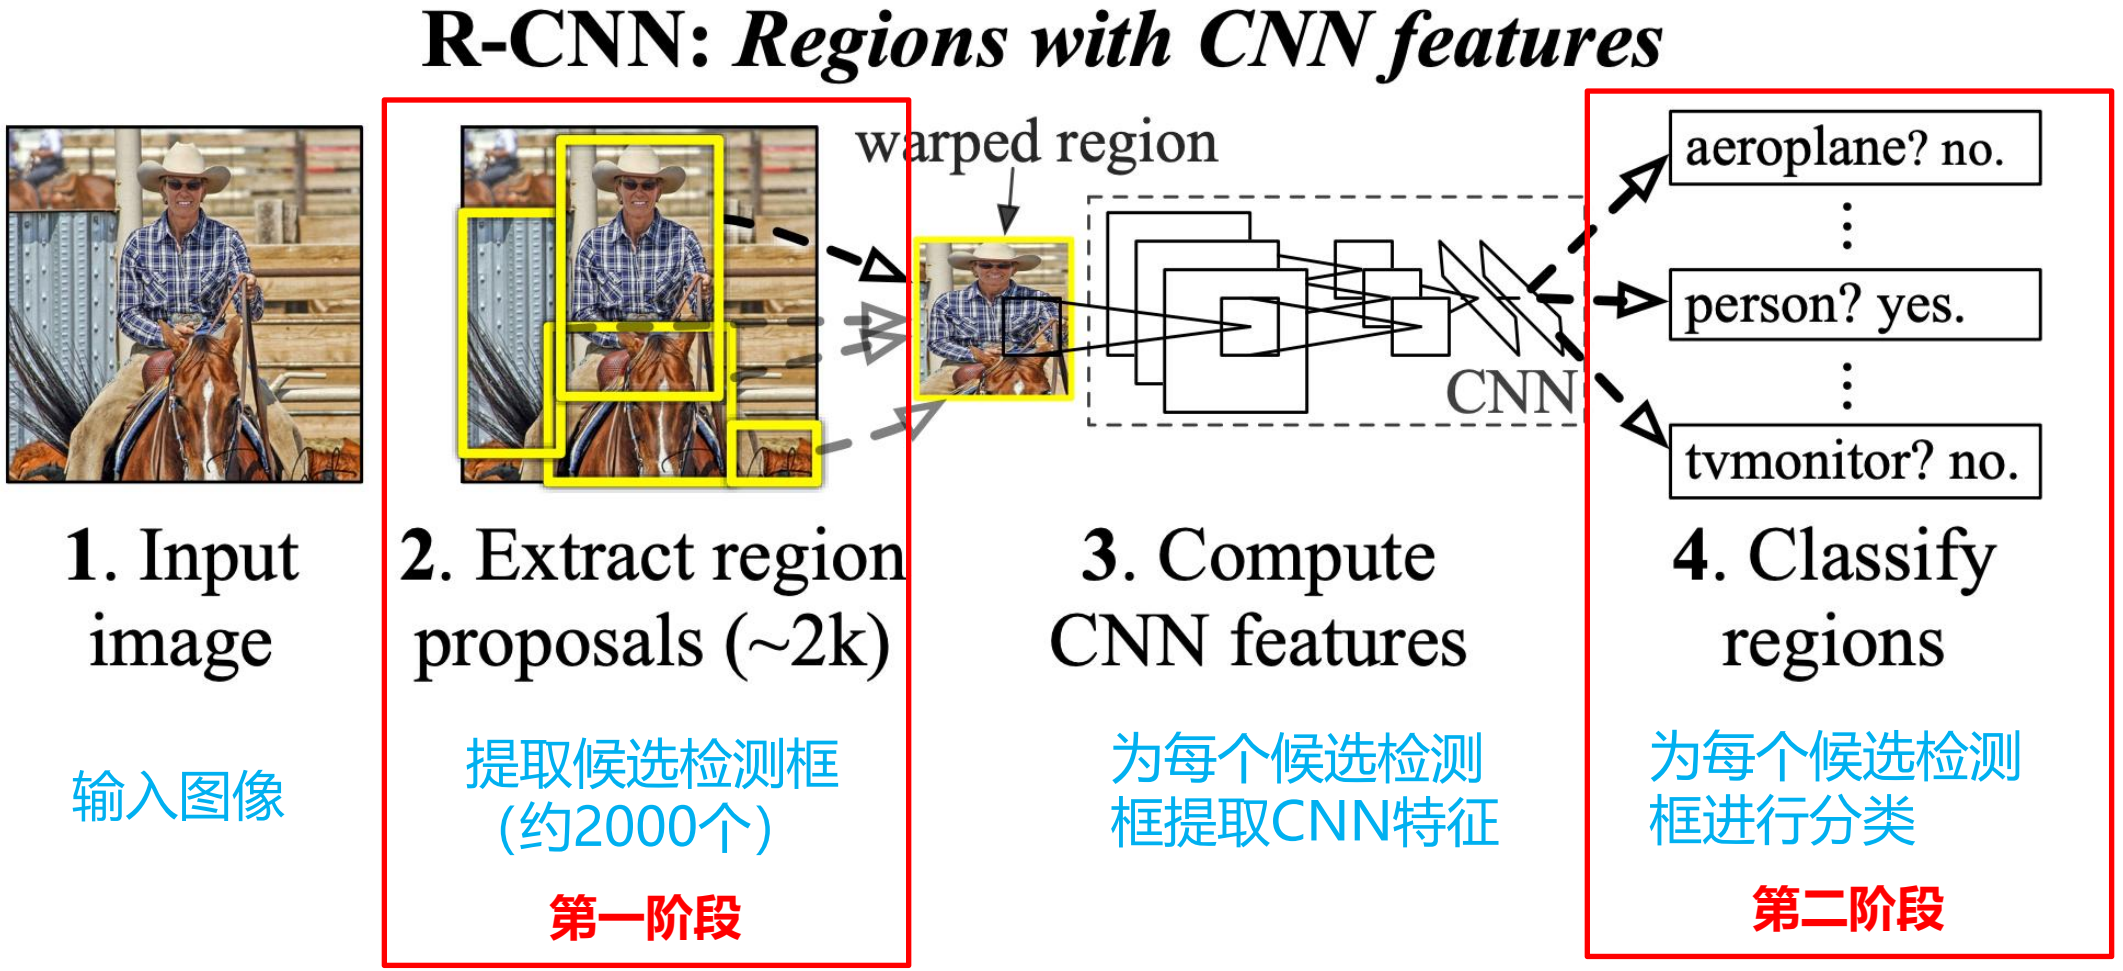
Many slides adapted from P. Viola

Part 2

两阶段方法

两阶段之R-CNN

符合我们一般思维的检测方法

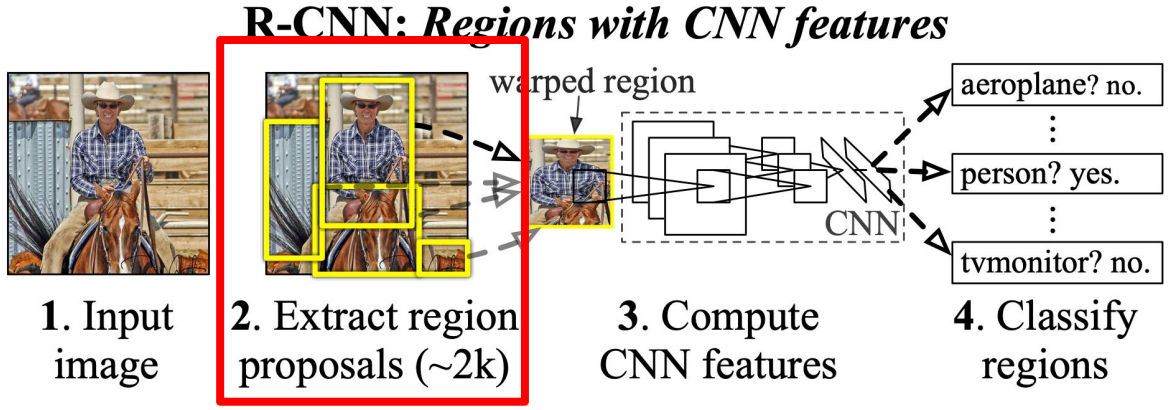


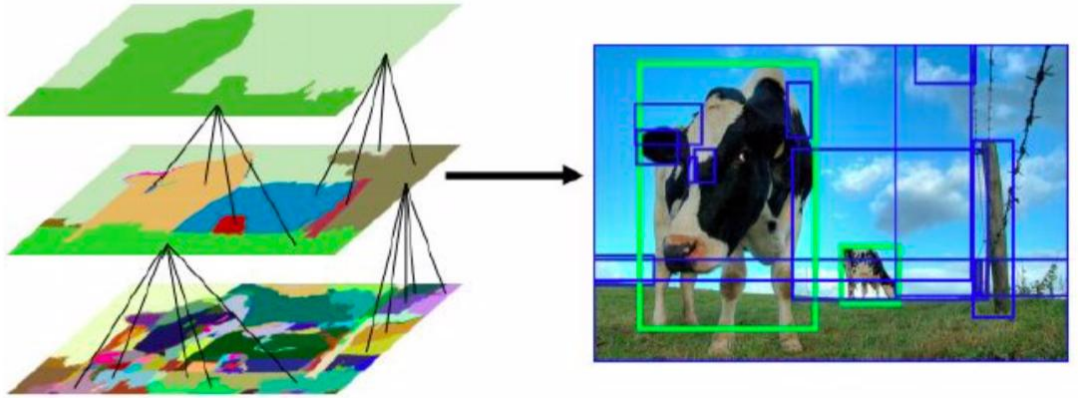
Ross B. Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik, "Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation," CVPR 2014

两阶段之R-CNN

候选区域生成

类似于一种层次聚类算法

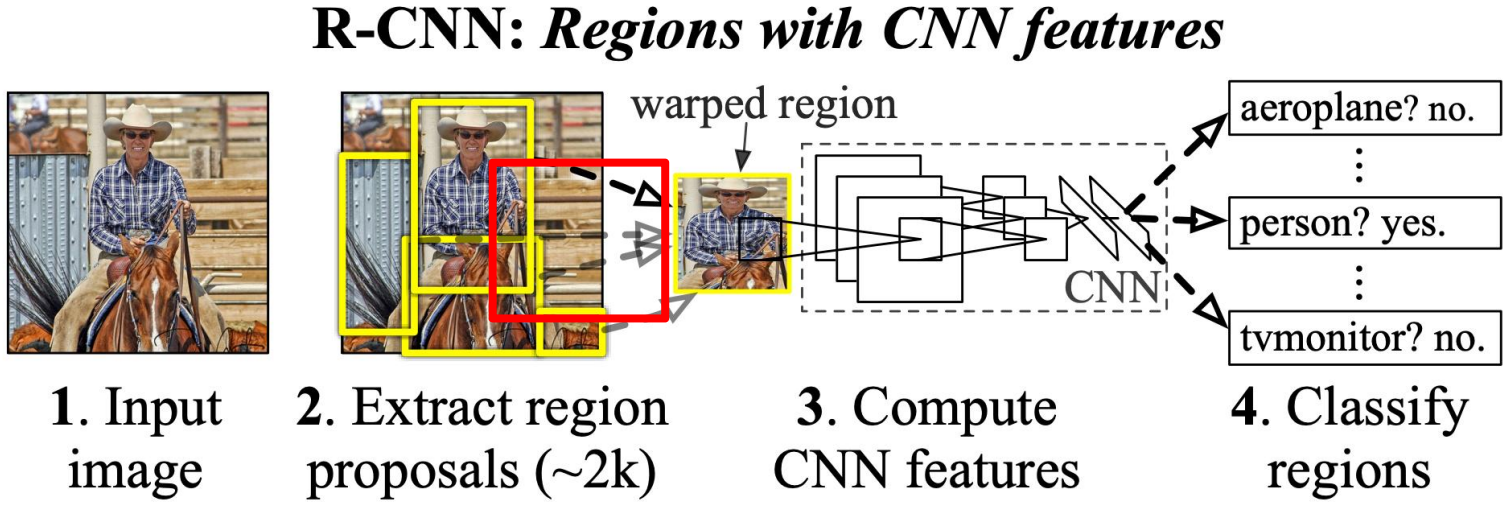




- Selective Search(SS，选择性搜索)：根据颜色、纹理、尺寸和空间交叠相似度提取约2000个region proposal(候选区域)
- 存在问题：
  - ✓ 对于每张图像，还需要额外的步骤提取region proposal
  - ✓ 存储和重复的提取每个region proposal的特征花费大量的存储和计算资源

两阶段之R-CNN

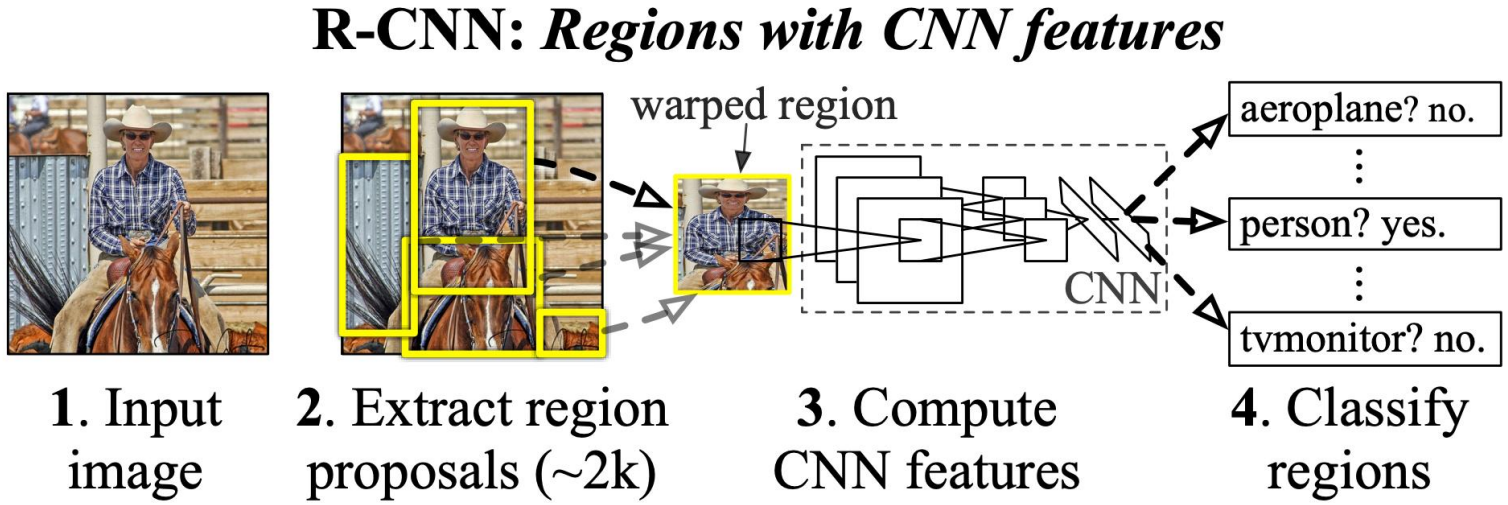
统一尺寸



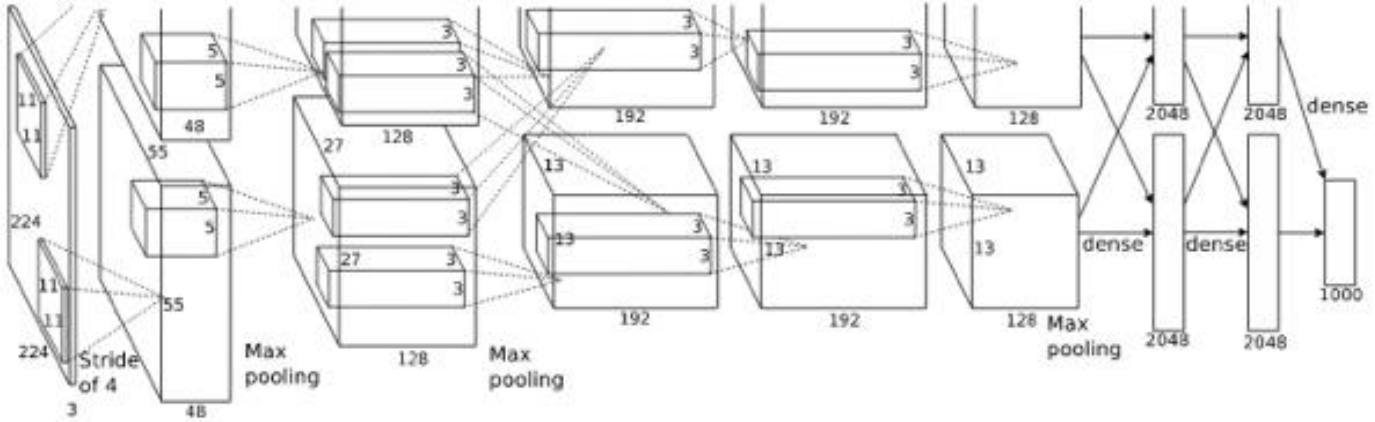
- Warped region (区域拉伸)：通过Selective Search产生的候选区域大小不一样，为了与CNN（AlexNet）兼容，R-CNN直接将所有的候选区域统一到227*227的尺寸
- 存在问题：
  - ✓ 将每个region proposal统一成同样的尺寸，严重影响CNN提取特征的质量

两阶段之R-CNN

特征提取

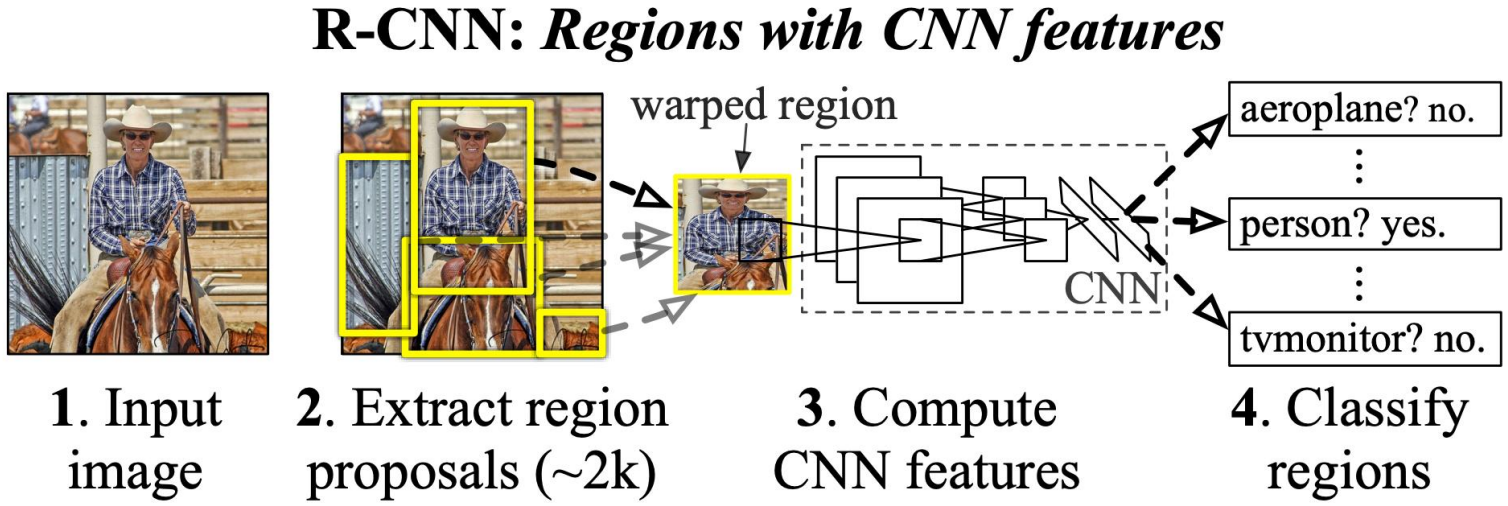


- 特征提取：
  - ✓ 通过卷积神经网络提取CNN特征，用于分类
- 存在问题：
  - ✓ 保存所有的目标候选区域的特征大约占用了200G的空间



两阶段之R-CNN

区域分类

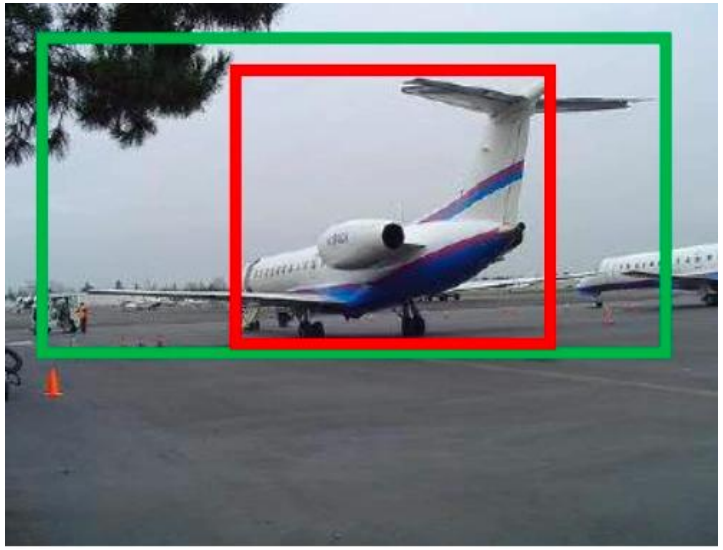


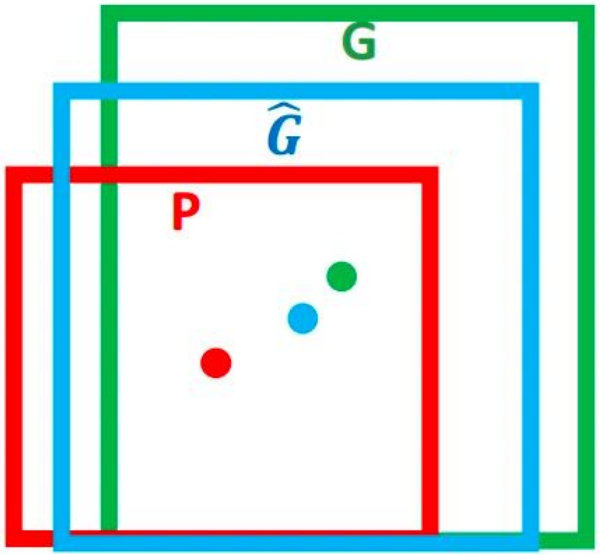
- Classify regions(区域分类): 为每一个类（包括背景类）训练SVM。
- 存在问题：
  - ✓ SVM需要单独的训练，使网络训练上更加复杂，随着类别的增加训练SVM的个数也随之增加。此外，逐个执行SVM分类也将消耗较多的时间

两阶段之R-CNN

边界框回归

学习一种映射关系，对目标候选的位置进行精化（Refine）：





- G：真实坐标
- P：RoI坐标（Selective Search获得）
- $\hat{G}$：修正后坐标

学习一种映射f，可最小化Region Proposal（p_x, p_y, p_w, p_h）和Ground Truth（G_x, G_y, G_w, G_h）的差异

$$f^2 p_x, p_y, p_w, p_h^{\ 3} = (\widehat{G_x}, \widehat{G_y}, \widehat{G_w}, \widehat{G_h}) \approx (G_x, G_y, G_w, G_h)$$

两阶段之R-CNN

第一个利用了深度学习的有影响力的目标检测工作

Rich feature hierarchies for **accurate object detection** and semantic segmentation

R Girshick, J Donahue, T Darrell… - … and pattern **recognition**, 2014 - cv-foundation.org

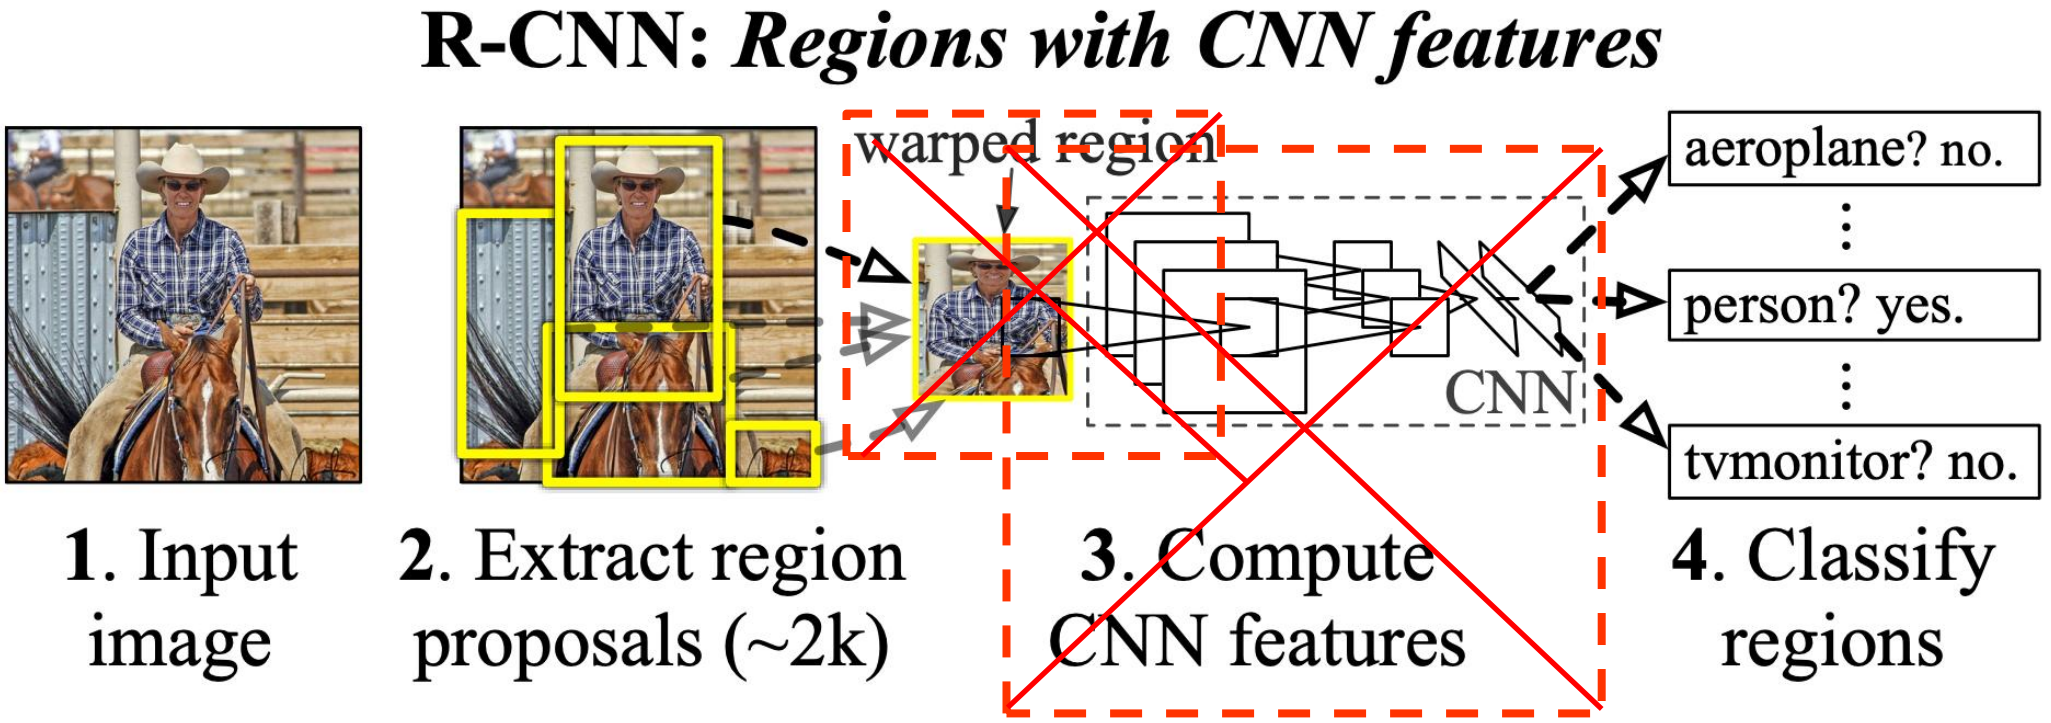
… **Features** matter. The last decade of progress on various visual **recognition** tasks has been … performance on the canonical visual **recognition** task, PASCAL VOC **object detection** [12], it is …

☆ Save 99 Cite Cited by 48238 Related articles All 46 versions »

回到2013年下半年（本人想象）

- 现在出来了一个新的图像处理神经网络，叫AlexNet，貌似很牛
- 我们（作者）能干点什么？
  - 貌似它可以用做特征提取器，我试试看
  - 就算提的特征好，它也只能改善目标检测中的一小步
  - 不管了，这似乎是一个有前途的方向，能做什么就先做点什么把
  - 第一个工作，题目怎么起好，其它部分怎么优化，其实都没有想清楚

两阶段之SPP-Net



输入图像

提取候选检测框（约2000个）

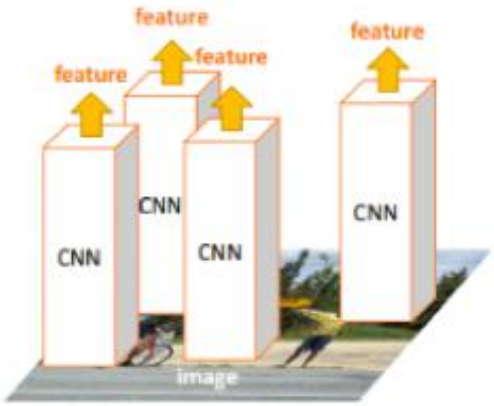
为每个候选检测框提取CNN特征

为每个候选检测框进行分类

He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. “Spatial pyramid pooling in deep convolutional networks for visual recognition.“, ECCV 2014, PAMI2015

两阶段之SPP-Net

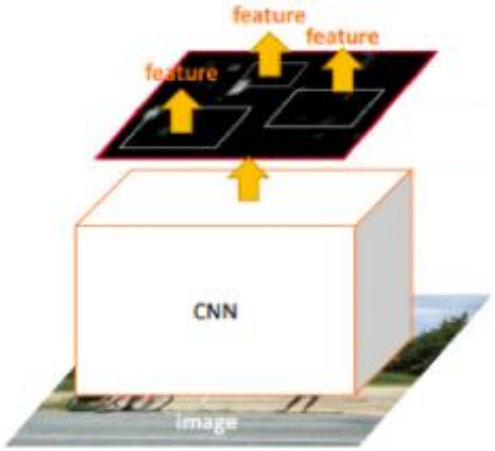
R-CNN缺点：为每个region proposal提取特征，花费大量的计算时间和存储空间。



R-CNN

2000 nets on image regions

逐个提取特征



SPP-NET

1 net on full image

一次性提取特征

SPP-Net不再单独提取每个候选区域的特征，而是一次性提取整个图像的特征，再在特征图上取出对应于不同region proposal的区域

减少了提取特征的时间，和用来存储特征的空间。

He, Kaiming, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. “Spatial pyramid pooling in deep convolutional networks for visual recognition.“, ECCV 2014, PAMI2015

两阶段之SPP-Net

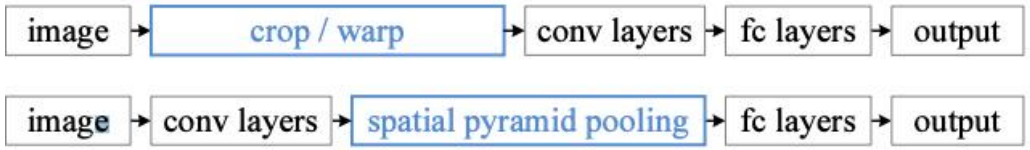
R-CNN缺点：使用Warp，为每个region proposal统一尺寸，严重影响CNN提取特征的质量



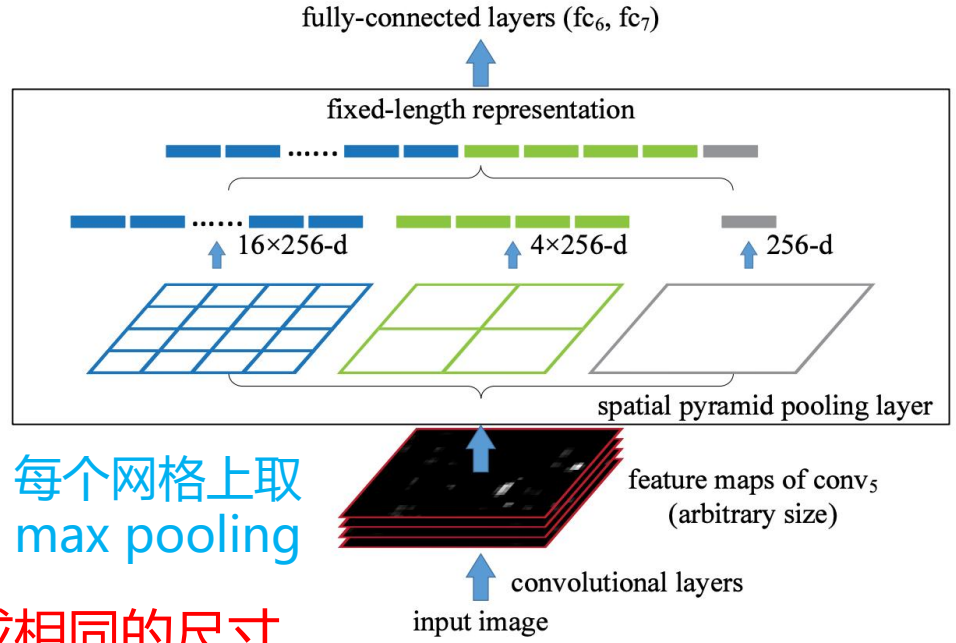
crop



warp



丢失信息/形态



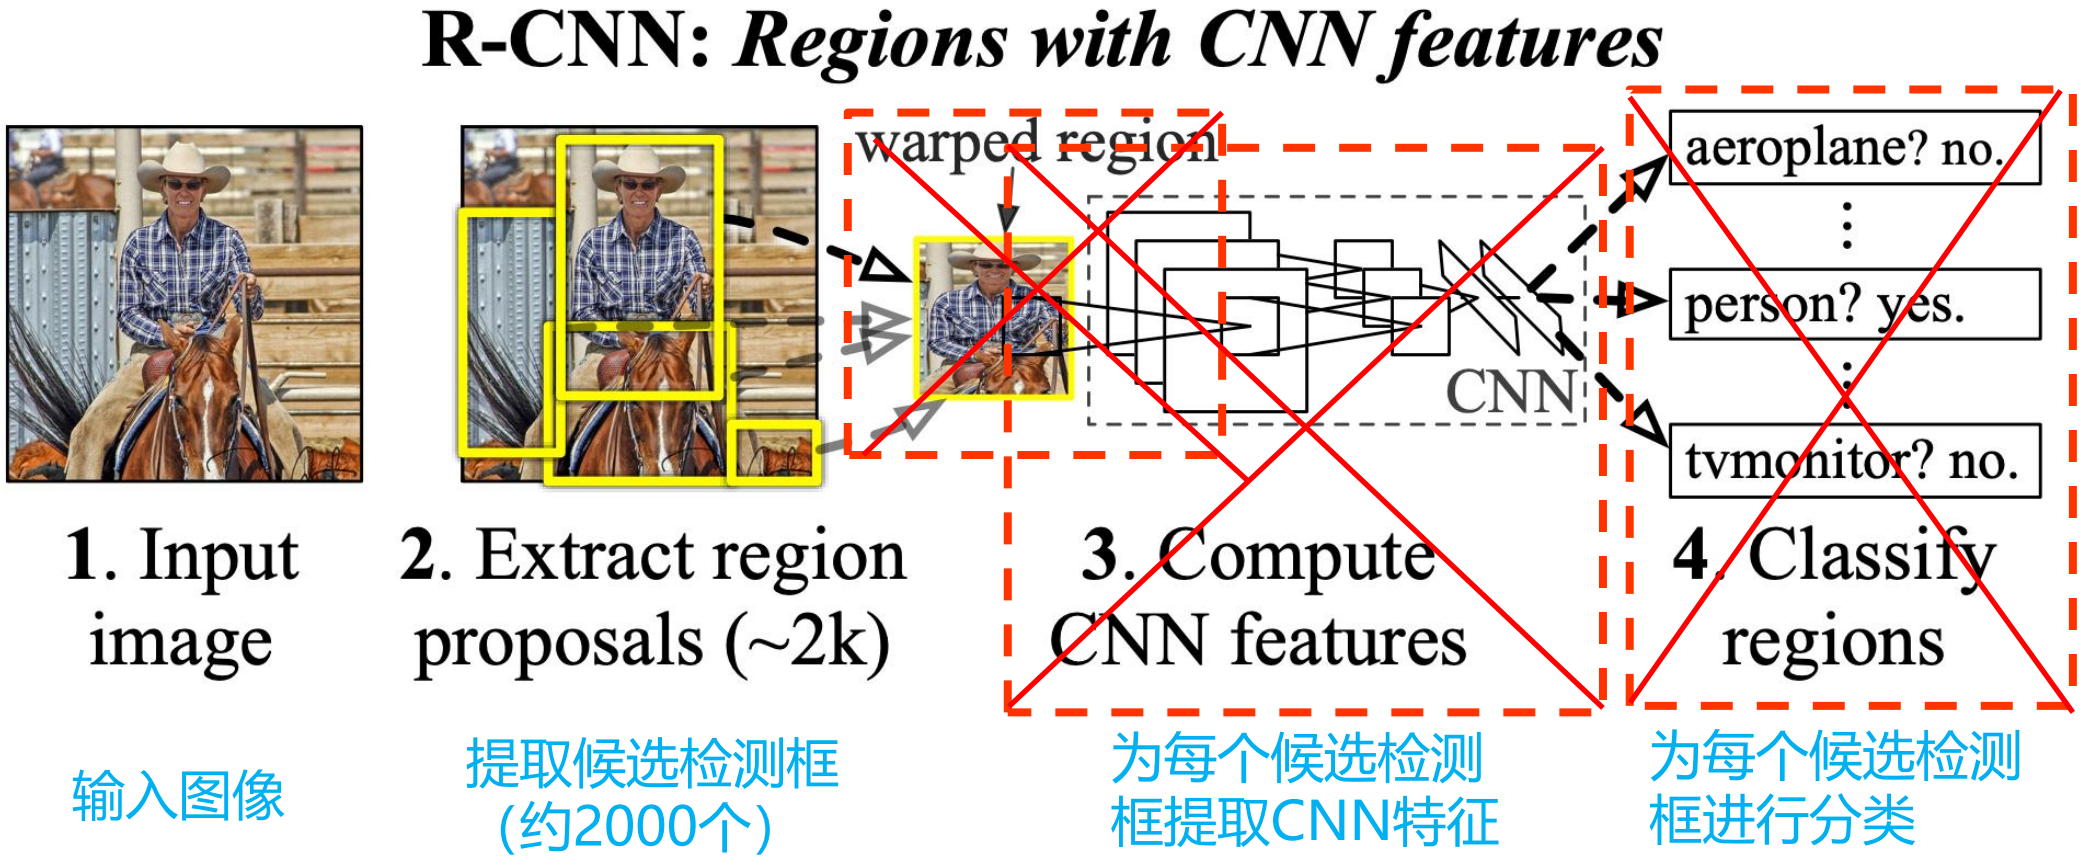
每个网格上取max pooling

通过spatial pyramid pooling将任意大小RoI特征统一成相同的尺寸

可以输入任意大小的候选区域，不再需要warp输入图像，

提升了CNN提取的特征的质量，使特征更鲁棒

两阶段之Fast R-CNN



输入图像

提取候选检测框（约2000个）

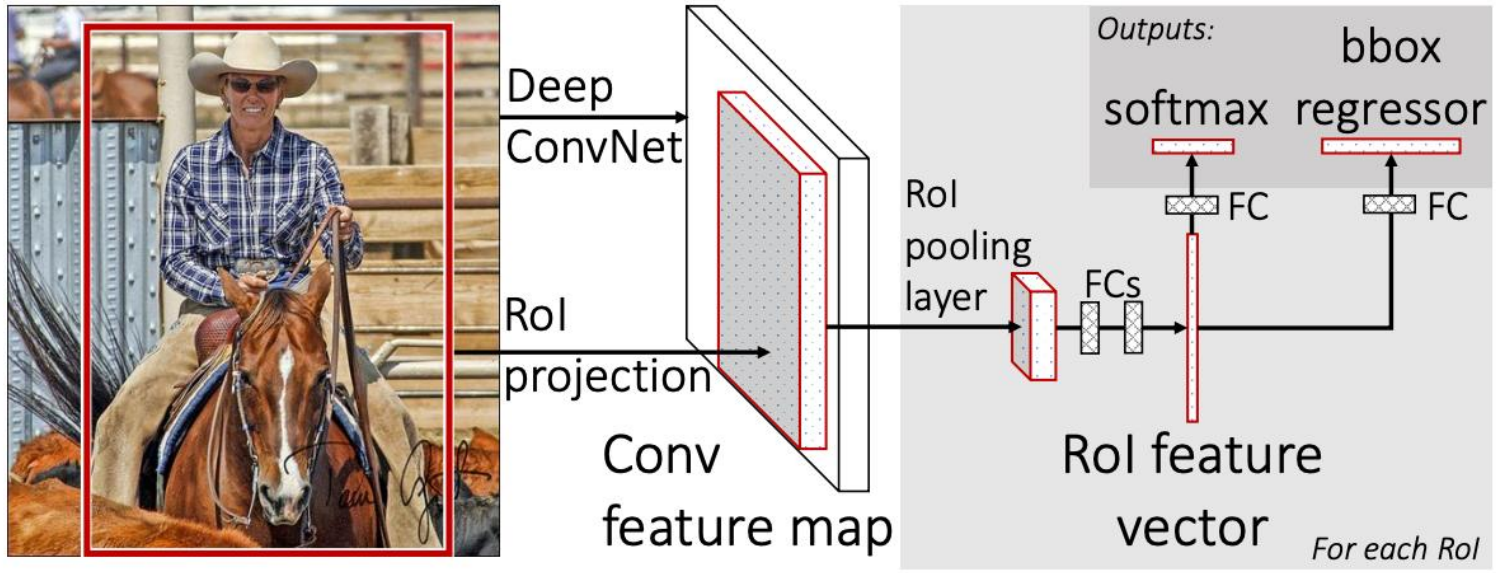
为每个候选检测框提取CNN特征

为每个候选检测框进行分类

Ross B. Girshick, “Fast R-CNN,” ICCV 2015

两阶段之Fast R-CNN

提取整幅图像的特征，在特征上进行Wrap



特征比图像抽象，学习过程可更好的适应弯曲和裁剪变化

- ✓ 整幅图像输入卷积神经网络提取特征
- ✓ 根据SS获得的RoI（Region Of Interest），在特征图提取对应的特征
- ✓ 得到的特征通过RoI Pooling统一到相同的大小

通过SS在图像中提取RoI->卷积网络提取特征->RoI Pooling->全连接层->分类/边界框回归

两阶段之Fast R-CNN

RoI Pooling

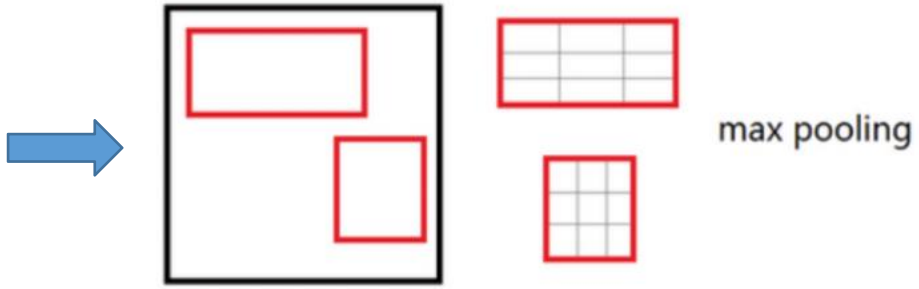
图像的warp->固定划分提取特征: RoI Pooling

示例：

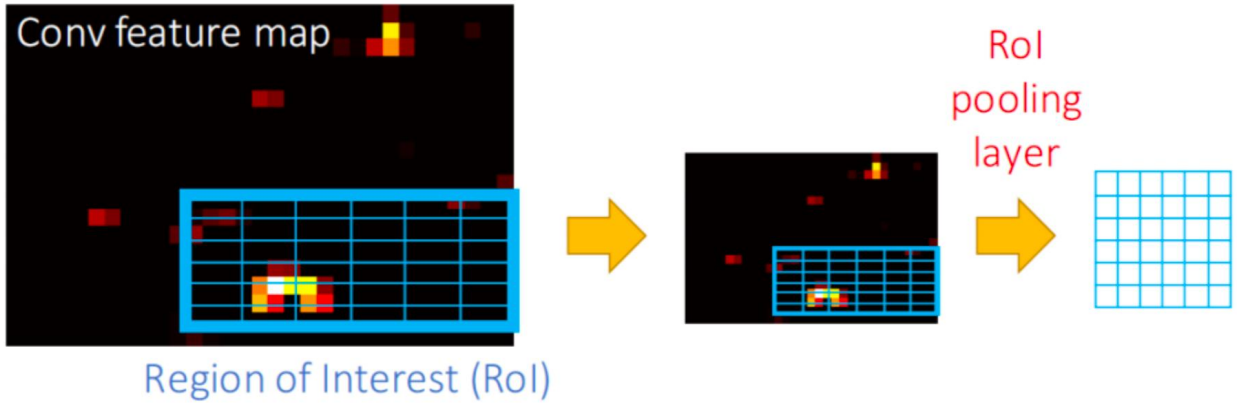
输入ROI特征图的大小：24*12　　max pooling: stride(4*2)

输入ROI特征图的大小：12*18　　max pooling: stride(2*3)

输出特征图：6*6



注：不能整除，则向下取整（丢弃小部分右侧和下侧像素）



◆ 与SPP-Net的异同：

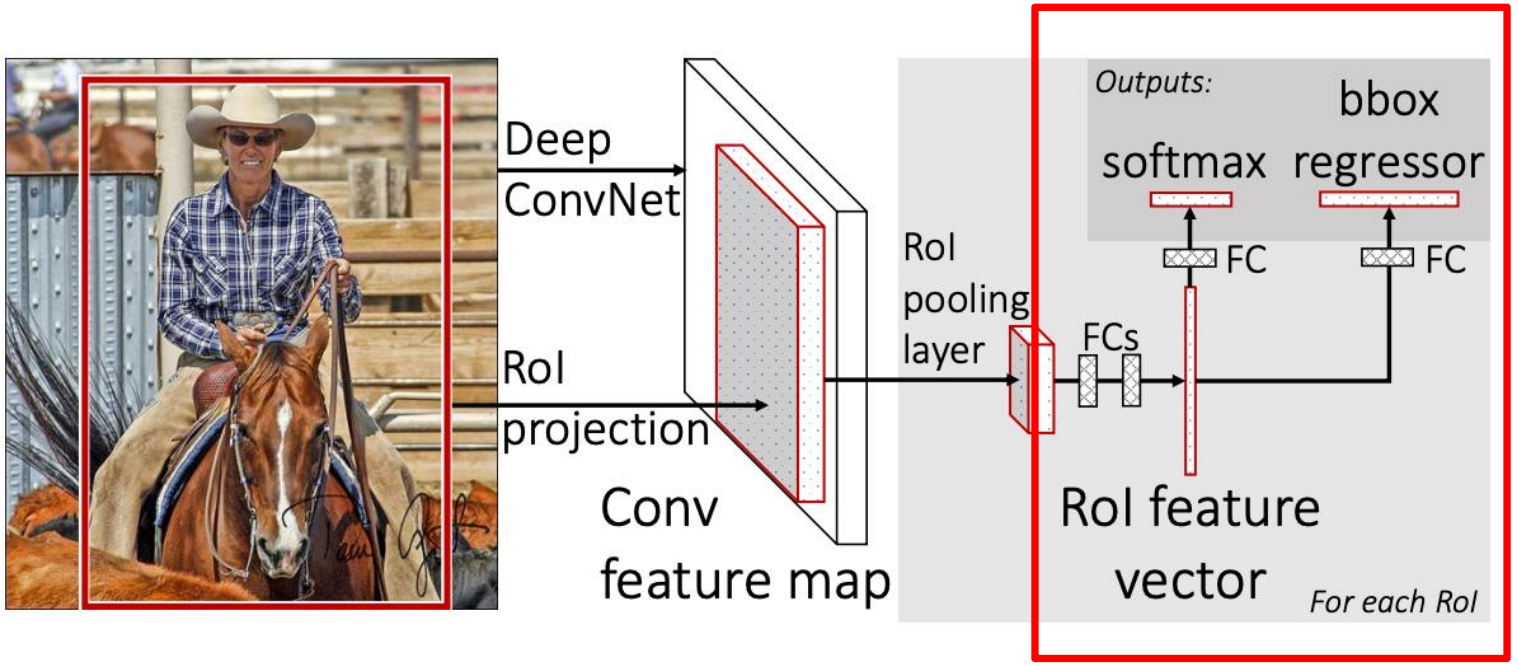
✓ 都是特征而不是图像的warp

✓ SPP-Net是空间金字塔池化

✓ Fast R-CNN是RoI pooling

两阶段之Fast R-CNN

将分类损失和回归损失统一在同一个框架中



分开的svm+bbox

⬇

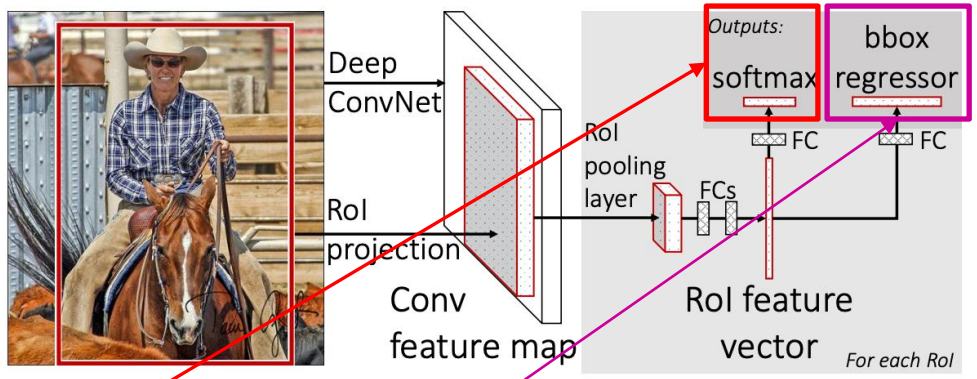
多任务损失（softmax+regressor）

两个任务一起优化，互相促进和增强

通过SS在图像中提取RoI->卷积网络提取特征->RoI Pooling->全连接层->分类/边界框回归

两阶段之Fast R-CNN

多任务损失



为什么用smooth_L1?

真实边界框坐标（x,y,w,h）

预测的边界框坐标（$\hat{x}, \hat{y}, \hat{w}, \hat{h}$）

$$L(p, u, t^u, v) = L_{\text{cls}}(p, u) + \lambda[u \geq 1] L_{\text{loc}}(t^u, v)$$

真实类别

预测的类别得分

分类损失

边界框回归损失-L1 loss

u=0为背景类，不对应任何实际类别，无边界回归损失

$$L_{\text{loc}}(t^u, v) = \sum_{i \in \{\text{x,y,w,h}\}} \text{smooth}_{L_1}(t_i^u - v_i),$$

in which

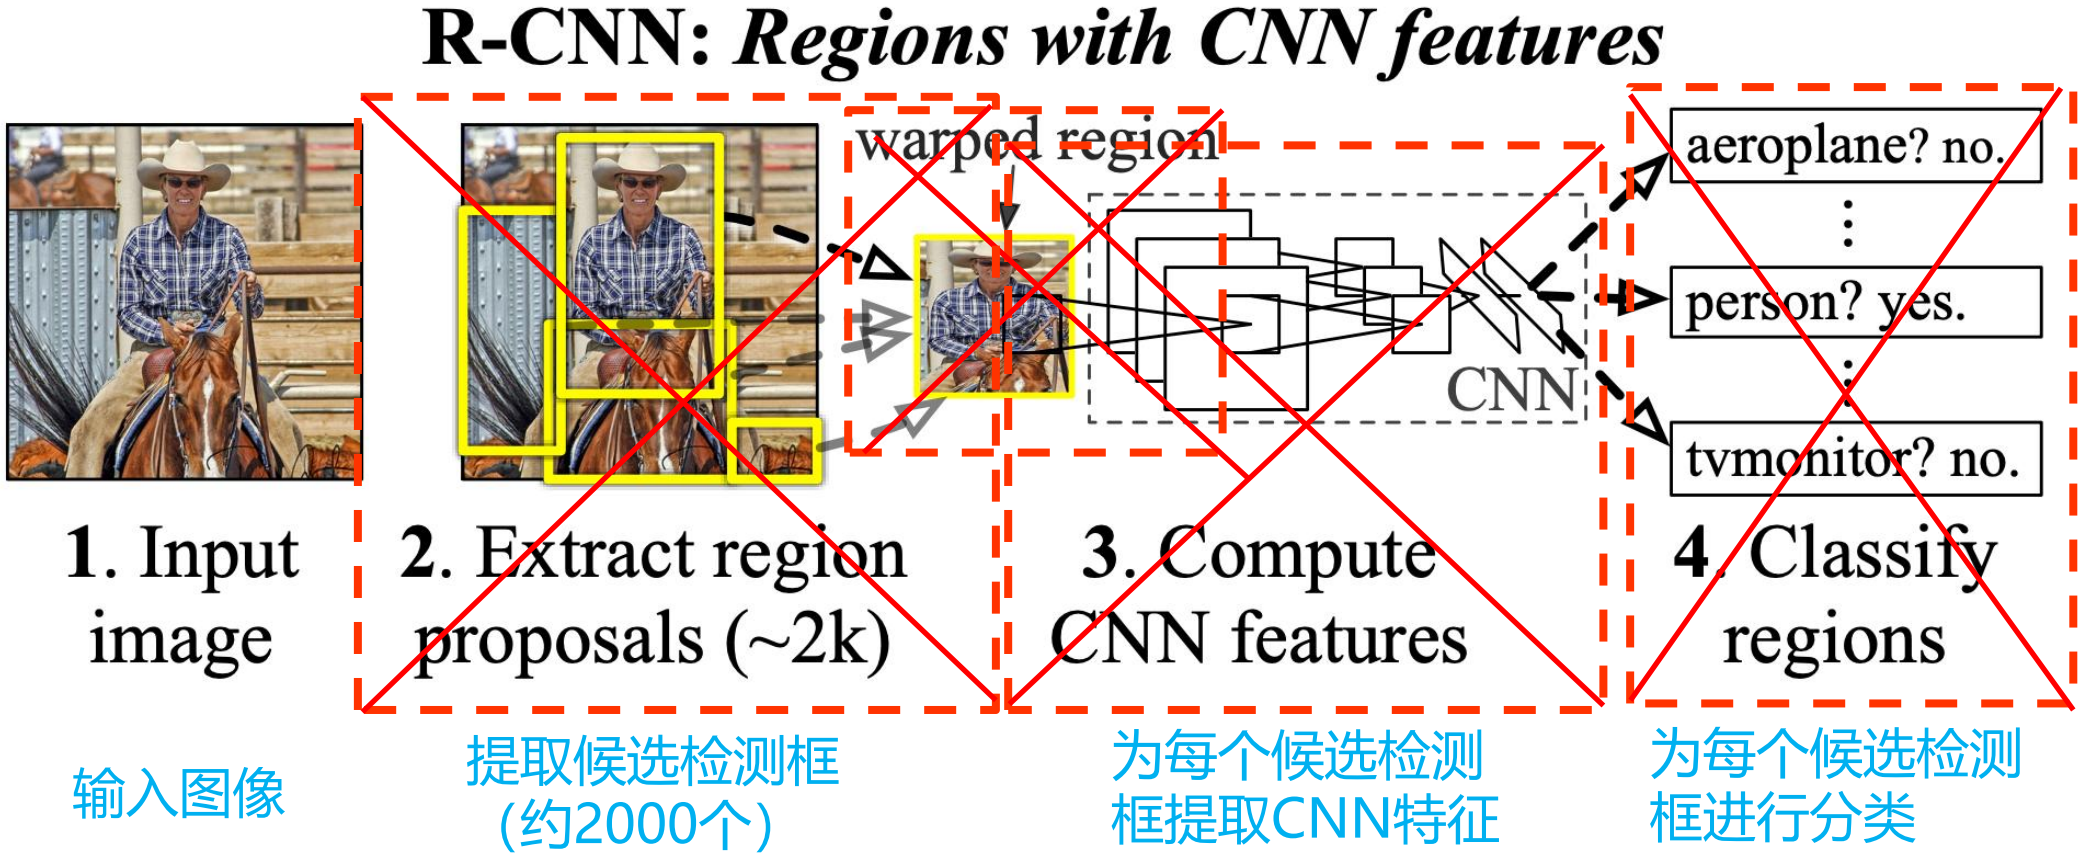
$$\text{smooth}_{L_1}(x) = \begin{cases} 0.5x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise,} \end{cases}$$

L1 loss

$$L_1 = |f(x) - Y|$$

$$L_1' = \pm f'(x)$$

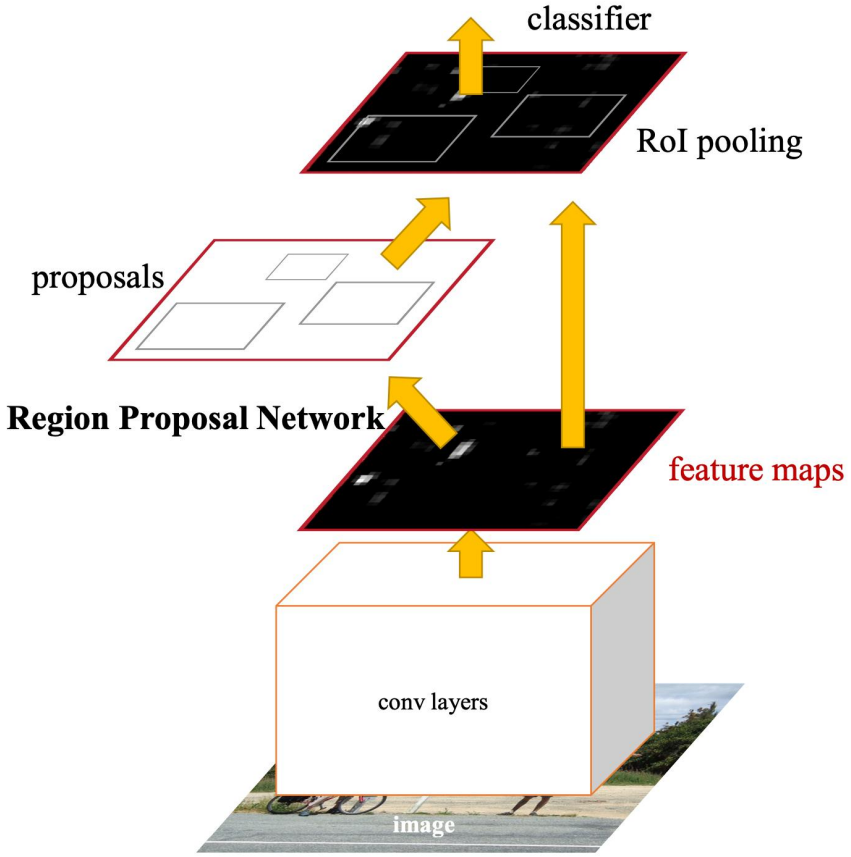
两阶段之Fast R-CNN



Shaoqing Ren, Kaiming He, Ross B. Girshick, Jian Sun, “Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks,” NIPS 2015

两阶段之Fast R-CNN

端到端检测网络，极大提升了检测速度



◆如何实现：

- ✓ 在最后一个卷积层后面添加Region Proposal Network (RPN)
- ✓ 候选区域由RPN网络直接生成，不再依靠额外的候选区域生成算法（如SS）
- ✓ 由RPN网络提取候选区域后，类似Fast R-CNN，使用RoI Pooling，再使用两个分支分别计算类别和边界框回归

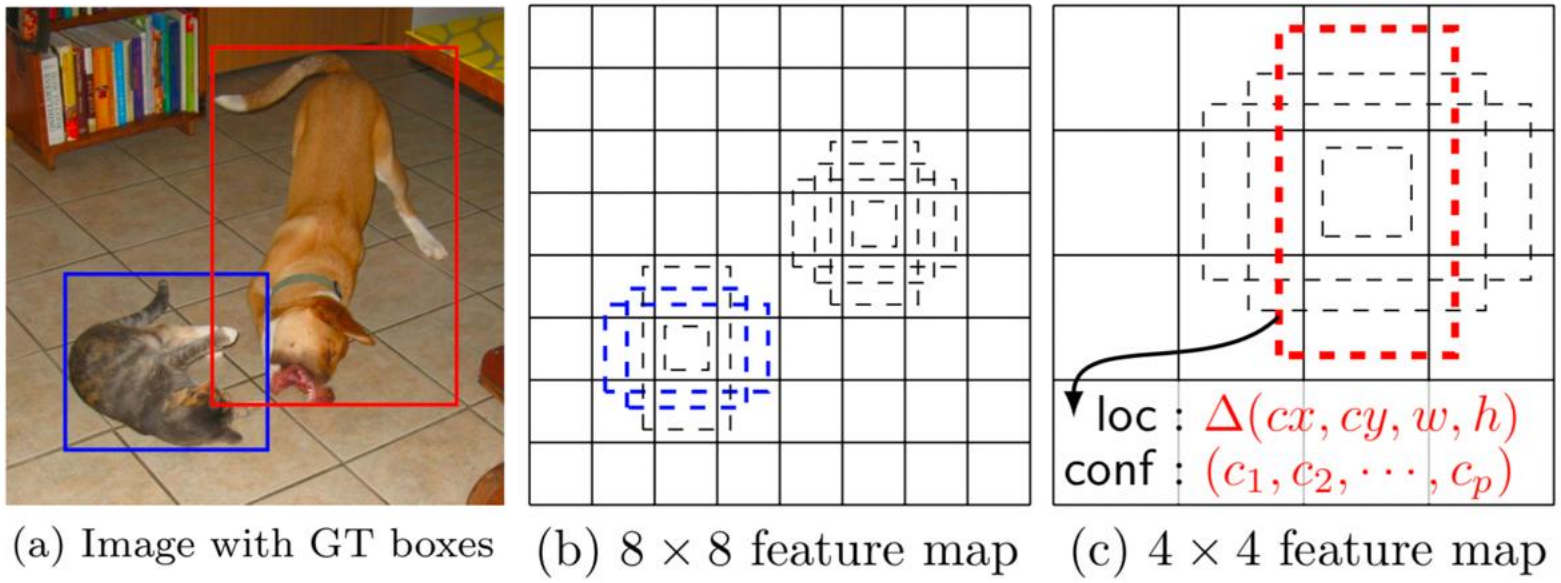
Part 3

一阶段方法

SSD

default box：速度快，精度高

一阶段方法速度快，但精度低
两阶段方法精度高，但速度慢



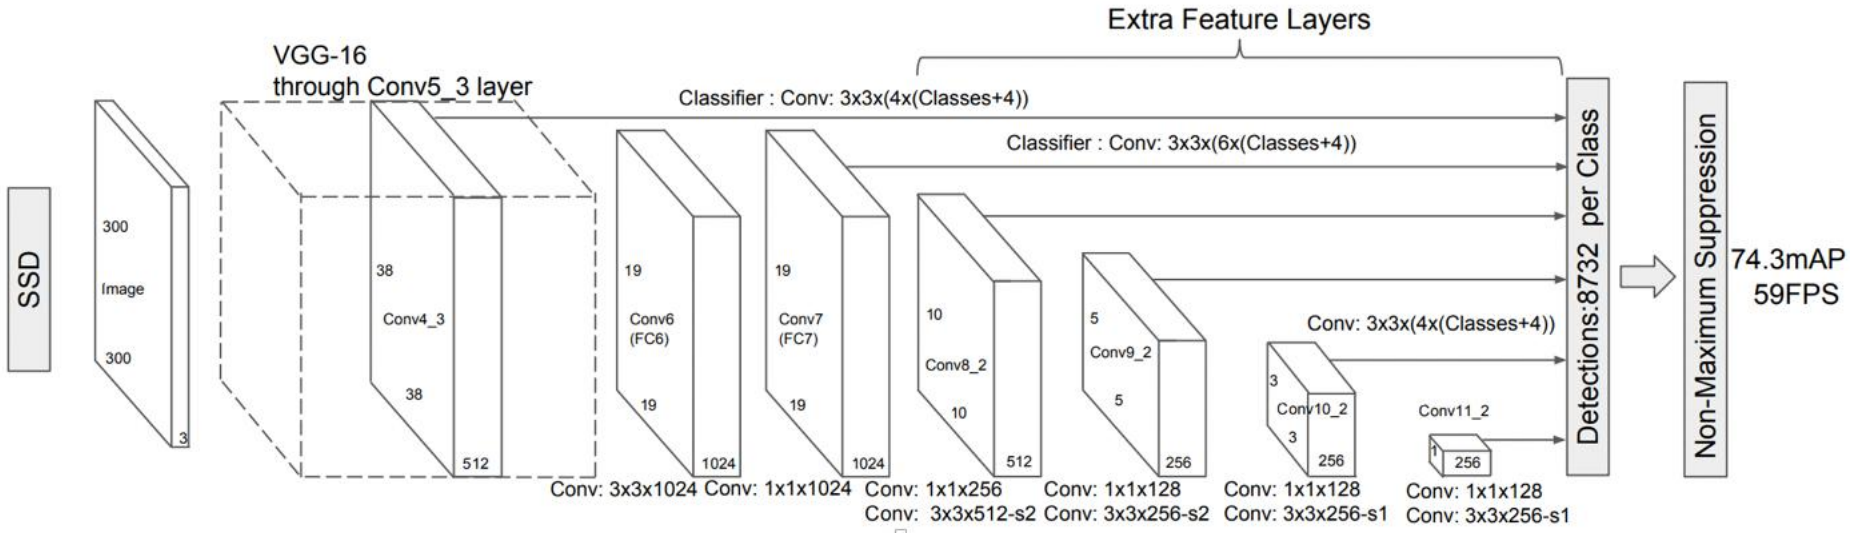
(a) Image with GT boxes (b) 8×8 feature map (c) 4×4 feature map

- ✓ 对于一张特征图，在每一个位置上提取预设数量的**anchor box**
- ✓ 直接在特征图上密集的提取proposal进行预测，使网络不需要先提取候选目标区域，速度大幅度提升

SSD

速度快，精度高

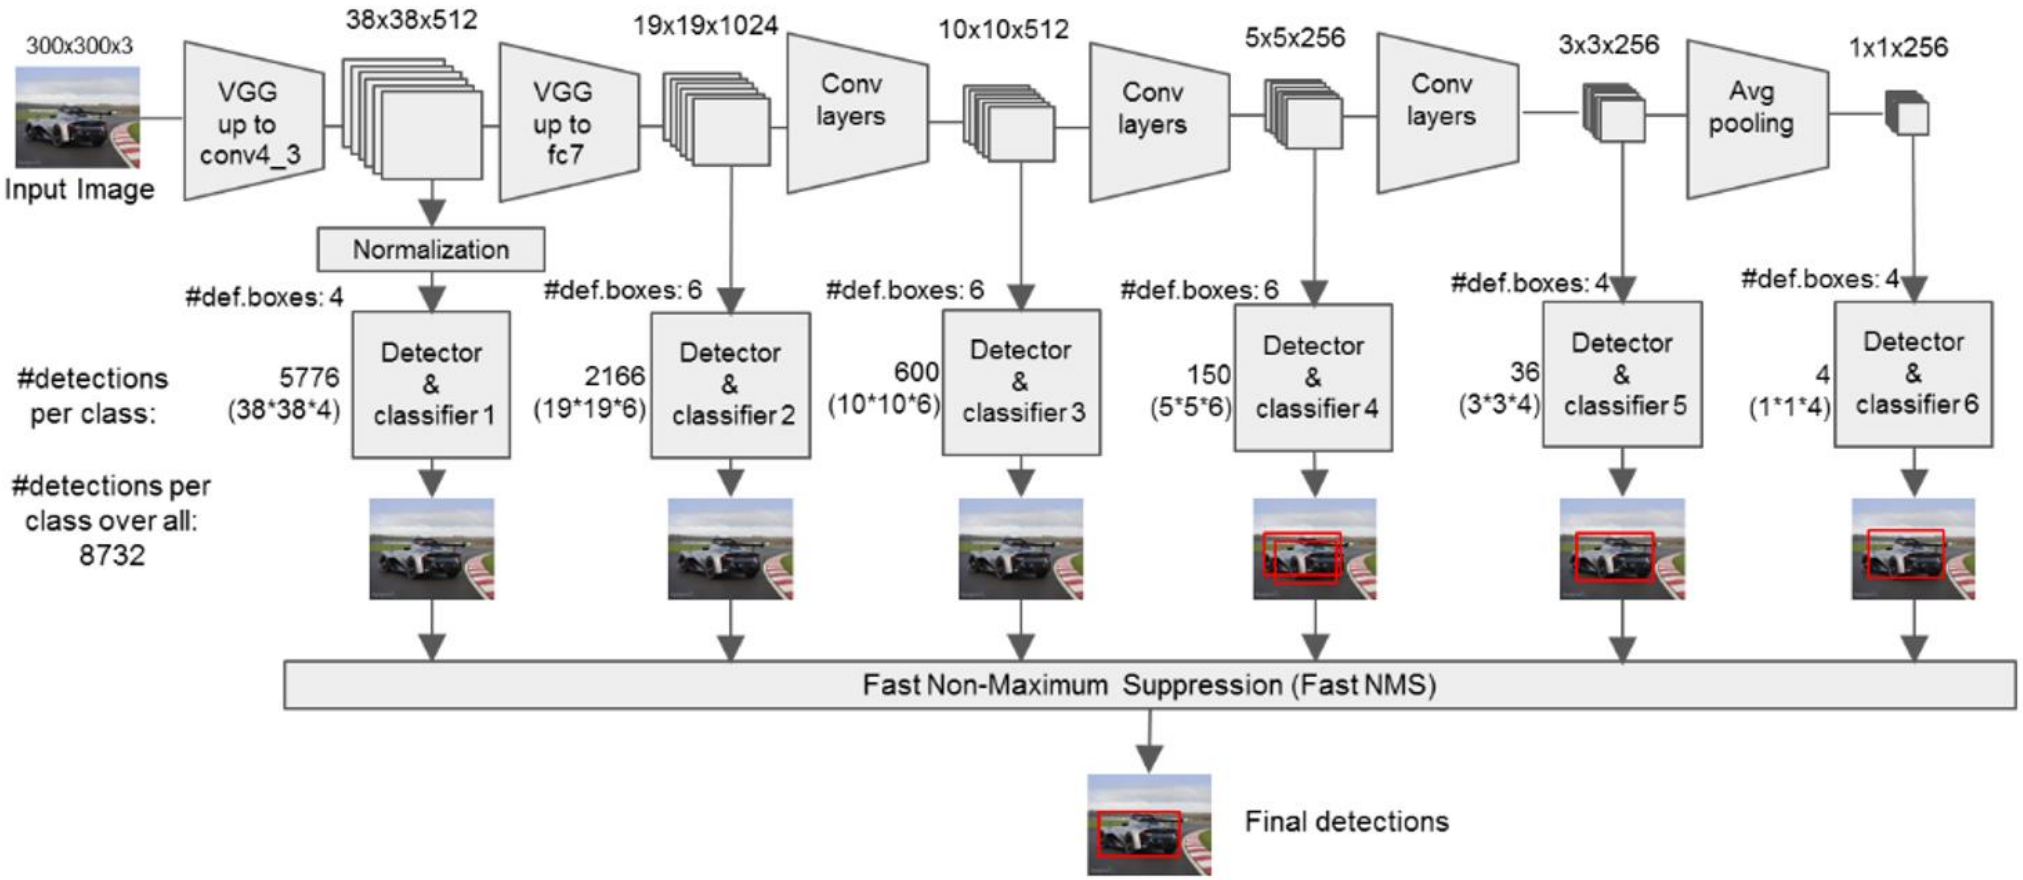
发挥计算优势的“穷举扫描”解法



- ✓ 在不同尺度的特征图预测，提高检测精度
- ✓ 不需要先确定候选区域，提高检测速度

Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott E. Reed, Cheng-Yang Fu, Alexander C. Berg, “SSD: Single Shot MultiBox Detector,” ECCV 2016

SSD

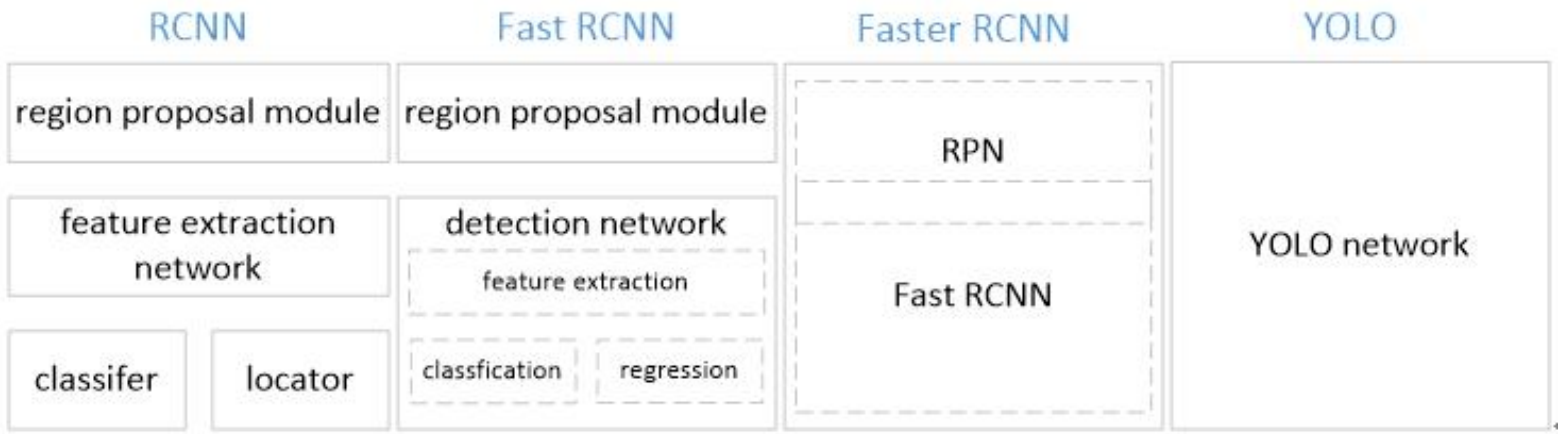


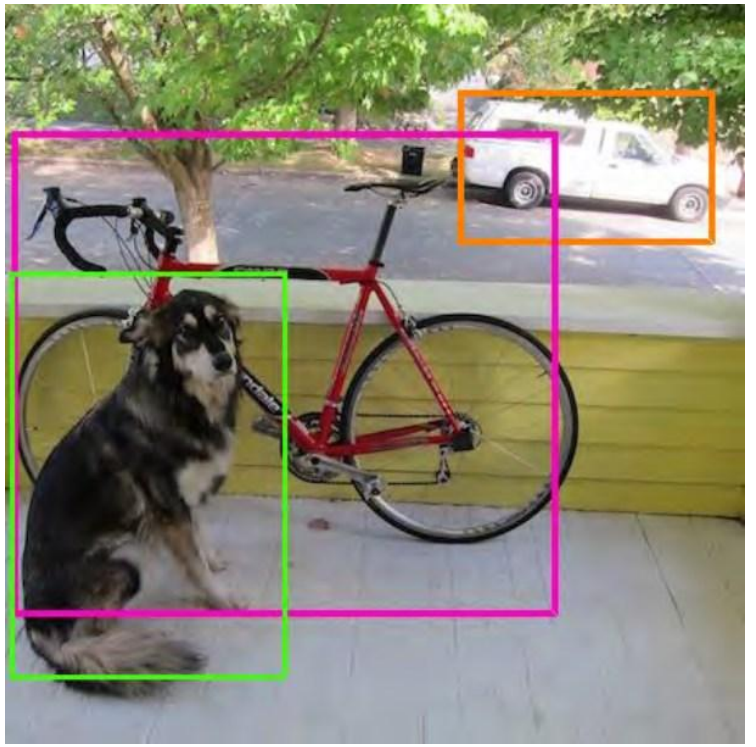
- ✓ 抽取Conv4_3、Conv7、Conv8_2、Conv9_2、Conv10_2、Conv11_2层的feature map，分别用于检测
- ✓ 将不同feature map获得的检测结果，通过NMS（非极大值抑制）方法来抑制掉一部分重叠或者不正确的，生成最终的检测结果

YOLO-V1

实时检测

You Only Look Once:
Unified, Real-Time Object Detection





- YOLO将物体检测作为一个回归问题进行求解，输入图像经过一次inference，便能得到图像中所有物体的位置和其所属类别及相应的置信概率
- 从2016年开始，已陆续提出了v1到v11多个版本，速度和性能不断提升

Joseph Redmon, Santosh Kumar Divvala, Ross B. Girshick, Ali Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” CVPR 2016

YOLO-V1

框架

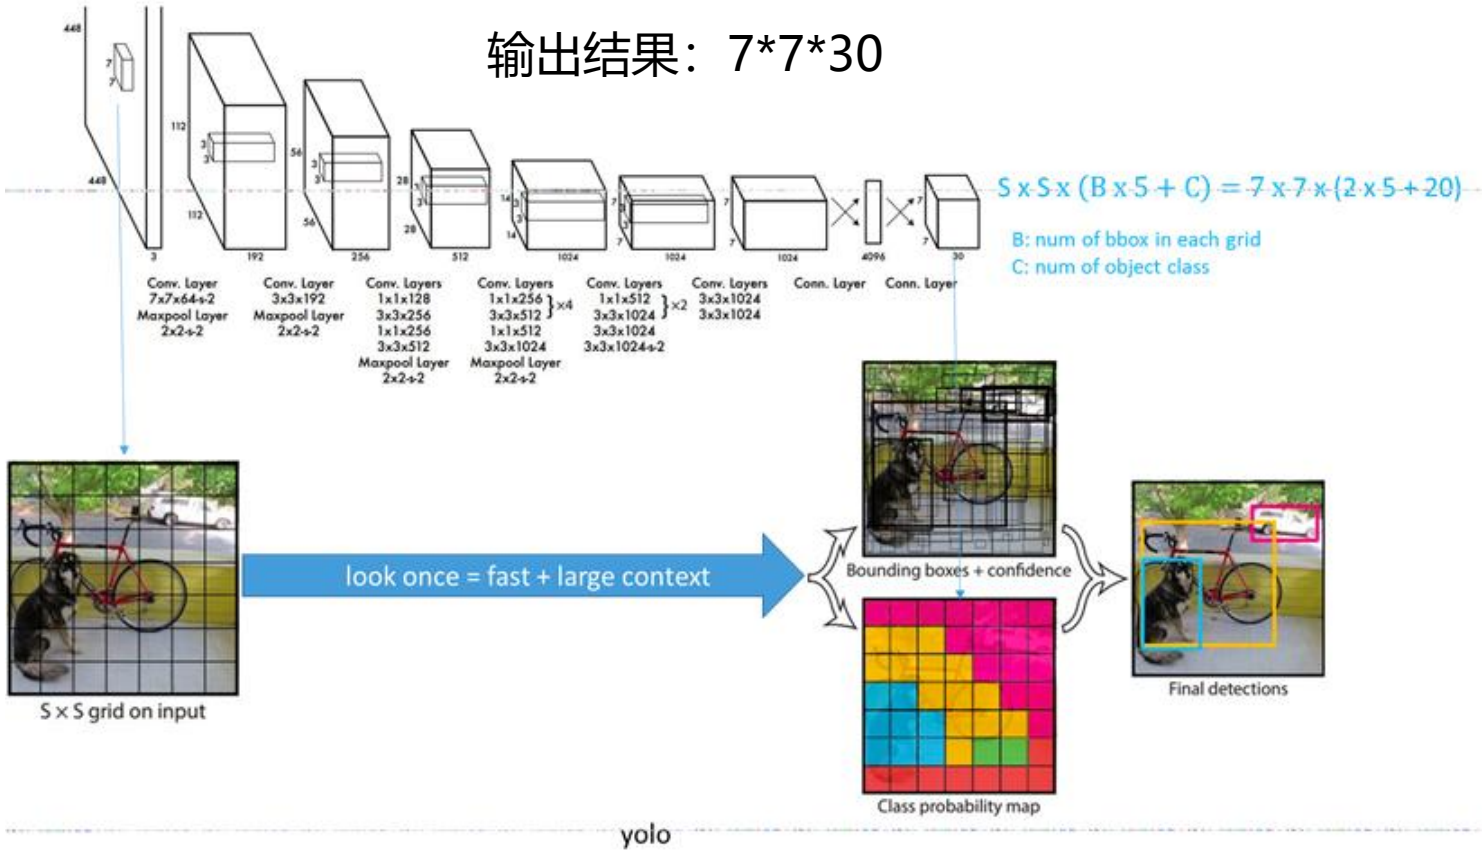
◆ 算法流程

- 将输入的图像划分成S*S个网格（S=7）
- 每个网格预测B个边界框和这个边界框是物体的概率(Objectness)。具体的，每个边界框会预测出5个值:x,y,w,h和置信度

  Pr(Object)*IoU(truth&pred)
- 每个网格预测C个类的概率

YOLO-V1主干网：修改的GoogleNet

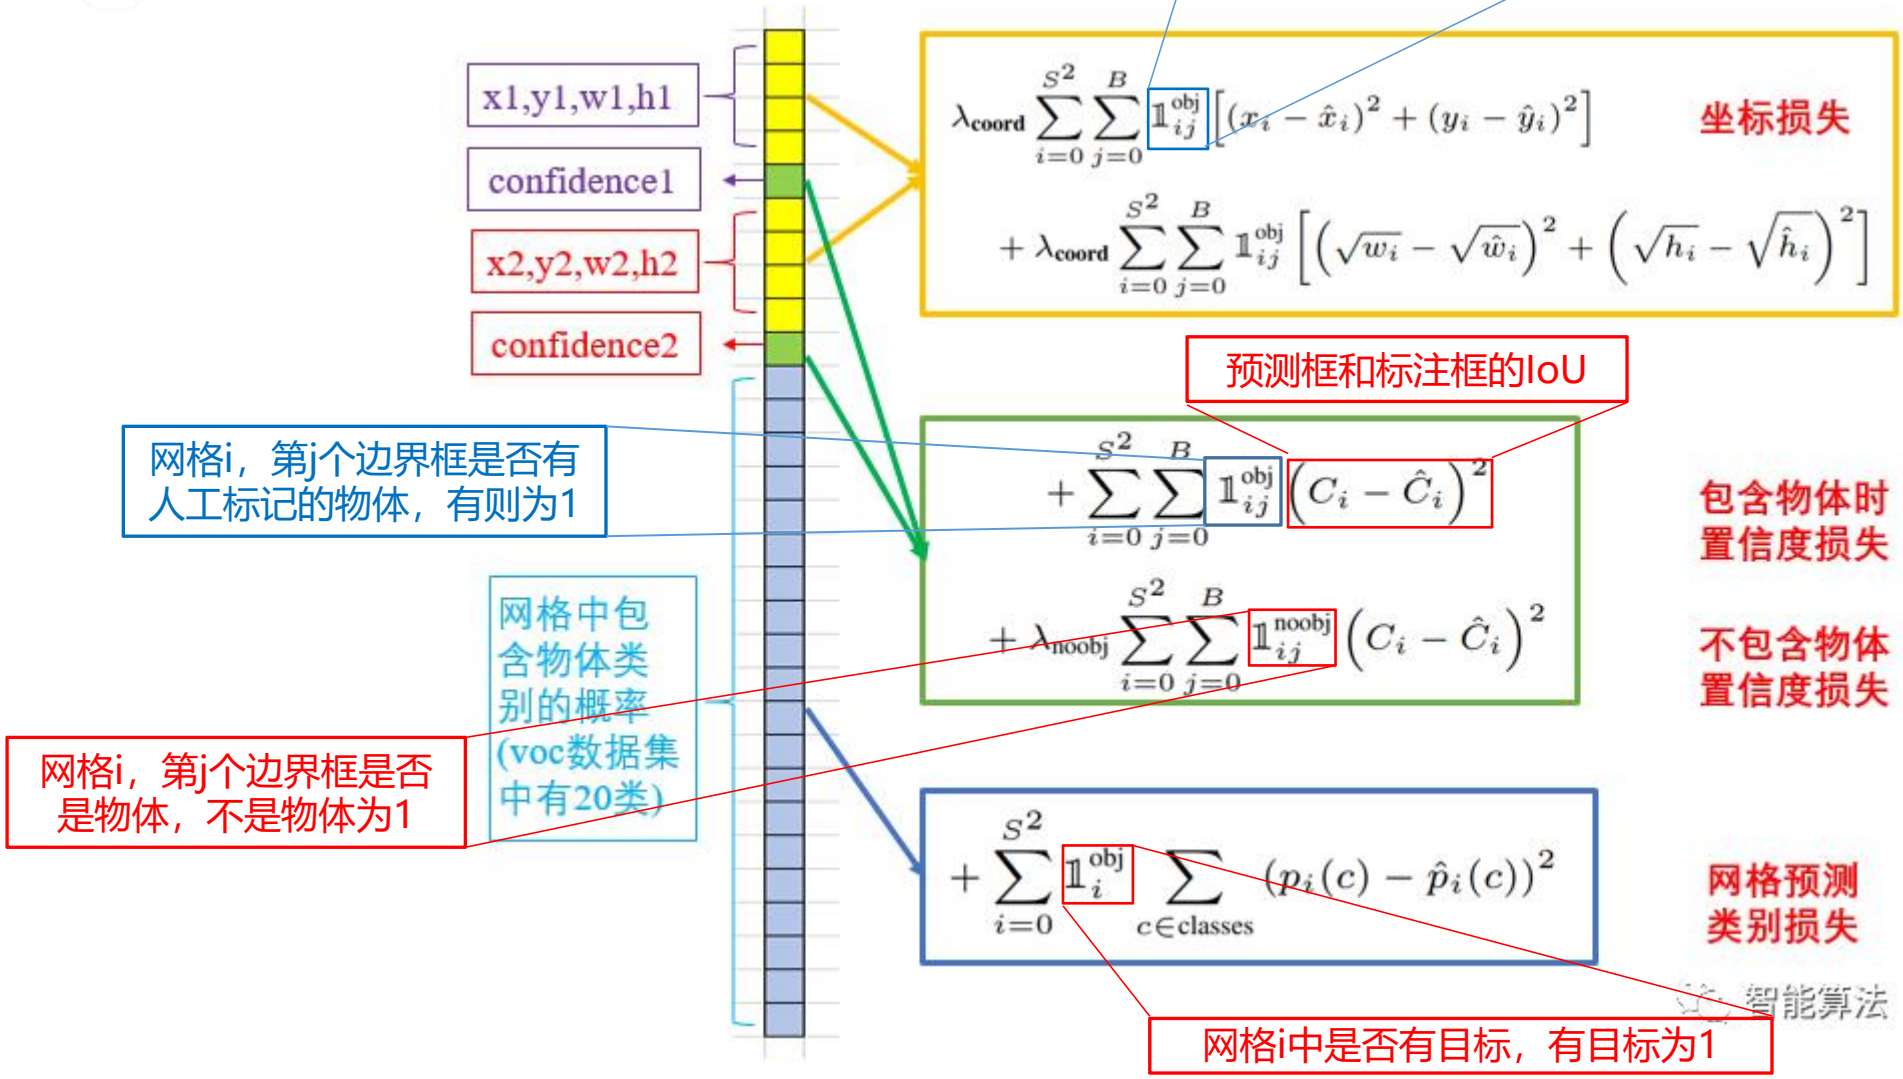
输出结果：7*7*30



训练时，有物体时中心点网格Pr(Object)=1，否则Pr(Object)=0

YOLO-V1

损失函数


x1,y1,w1,h1
confidence1
x2,y2,w2,h2
confidence2
表示由第i个网格中第j个边界框是否有人工标记的物体
$\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right]$
坐标损失
$+ \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right]$
边界框回归损失-均方误差
预测框和标注框的IoU
网格i，第j个边界框是否有人工标记的物体，有则为1
$+ \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{obj}} \left(C_i - \hat{C}_i \right)^2$
包含物体时置信度损失
前景预测置信度
网格中包含物体类别的概率(voc数据集中有20类)
$+ \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{\text{noobj}} \left(C_i - \hat{C}_i \right)^2$
不包含物体置信度损失
背景预测置信度
网格i，第j个边界框是否是物体，不是物体为1
$+ \sum_{i=0}^{S^2} \mathbb{1}_{i}^{\text{obj}} \sum_{c \in \text{classes}} \left(p_i(c) - \hat{p}_i(c) \right)^2$
网格预测类别损失
预测物体类别
网格i中是否有目标，有目标为1

Part 4

基于卷积的检测方法进展

FCOS

Anchor-free方法

通过回归特征图上每个位置距离目标框的上下左右距离来实现目标检测

用语义分割的思想逐像素点解决检测问题

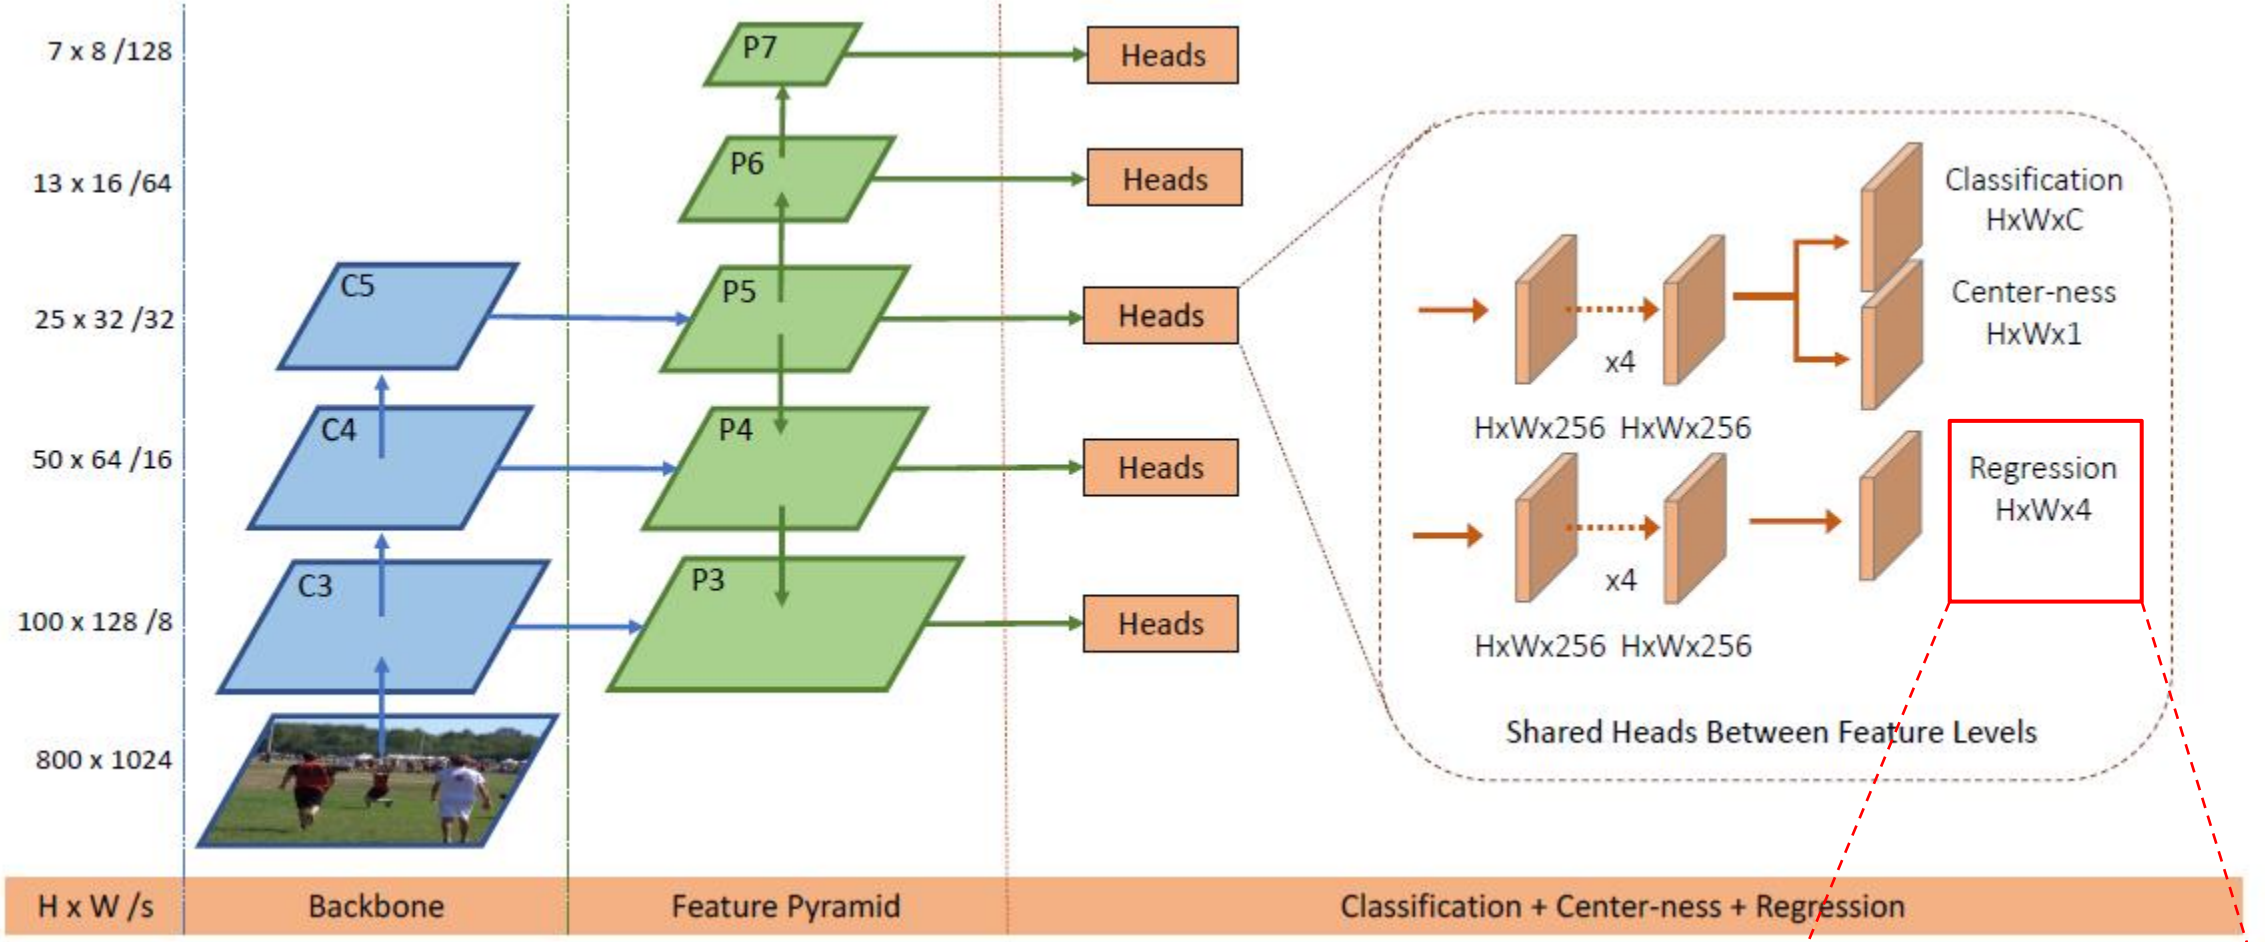
- anchor-based算法只关注gt box中心点所在的网格，并对相应锚框进行回归
- FCOS对于每个位置(x, y)，学习预测它到gt box的上，下，左，右的四个距离[t, b, l, r]
- 框中的每个像素都作为正样本，不局限于中心点，对相应边框进行回归



Zhi Tian, Chunhua Shen, Hao Chen, Tong He, et al. FCOS: Fully Convolutional One-Stage Object Detection. CVPR 2019

FCOS

Anchor-free方法



ResNext+FPN网络作为backbone

每个位置到边界框上下左右的距离

FCOS

Anchor-free方法

Anchor-free下，问题形式的变化带来新的建模方式

- 距离目标中心较远的位置会产生很多低质量的预测边框，FCOS引入centerness抑制这些低质量的预测边界框
- centerness表示从该位置到中心点的距离，距离最近时为1，距离越远centerness越小

$$\text{centerness}^* = \sqrt{\frac{\min(l^*, r^*)}{\max(l^*, r^*)} \times \frac{\min(t^*, b^*)}{\max(t^*, b^*)}}.$$

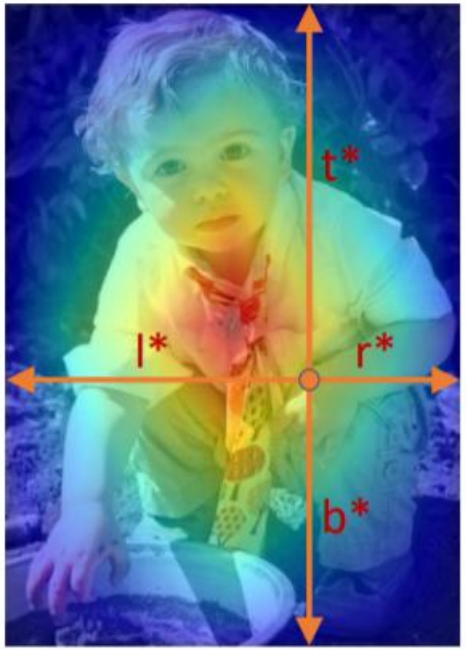


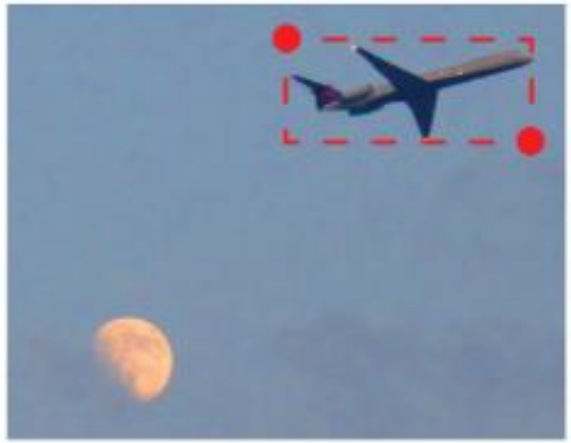
Figure 3 – Center-ness. Red, blue, and other colors denote 1, 0 and the values between them, respectively. Center-ness is computed by Eq. (3) and decays from 1 to 0 as the location deviates from the center of the object. When testing, the center-ness predicted by the network is multiplied with the classification score thus can down-weight the low-quality bounding boxes predicted by a location far from the center of an object.

CornerNet

Anchor-free方法

用成对角点预测的目标检测模型





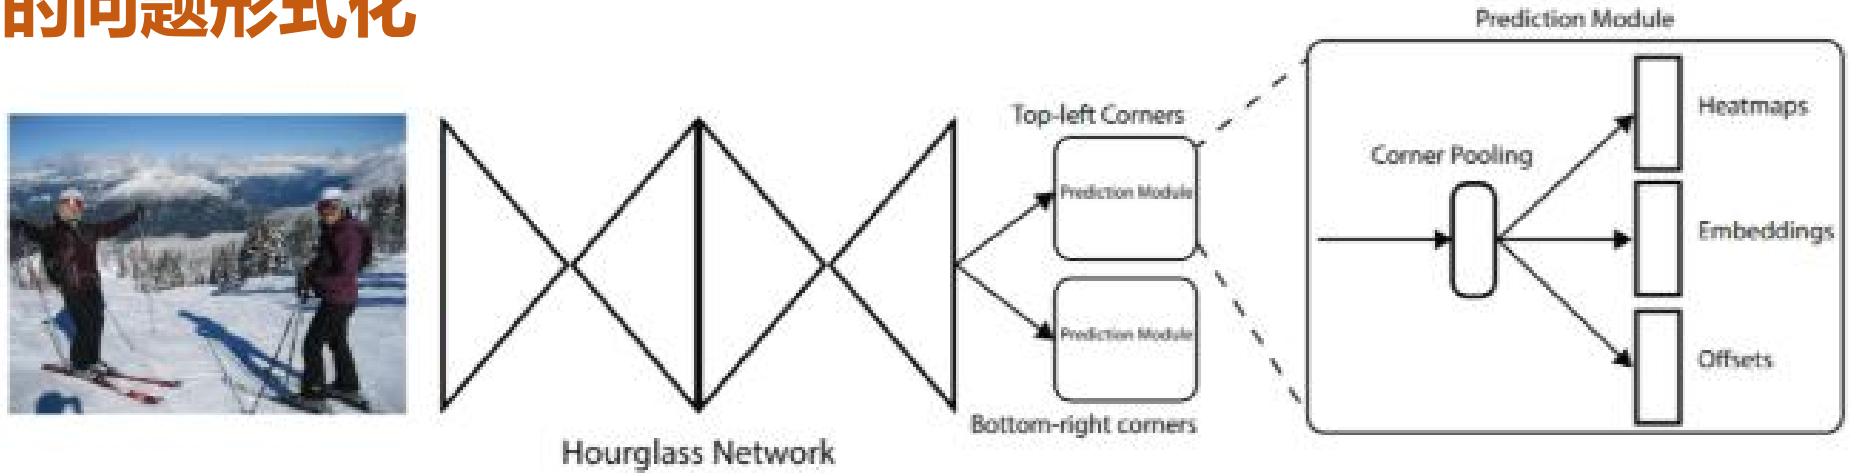
利用单个卷积网络将框的左上角及右下角两个点组成一对关键点，进而不需要设计在一阶段检测中大量的anchor boxes，同时，引入了corner pooling用于提升角点定位效果。

Law, Hei, Deng, Jia. CornerNet: Detecting Objects as Paired Keypoints, ECCV2018.

CornerNet

Anchor-free方法

优雅的问题形式化

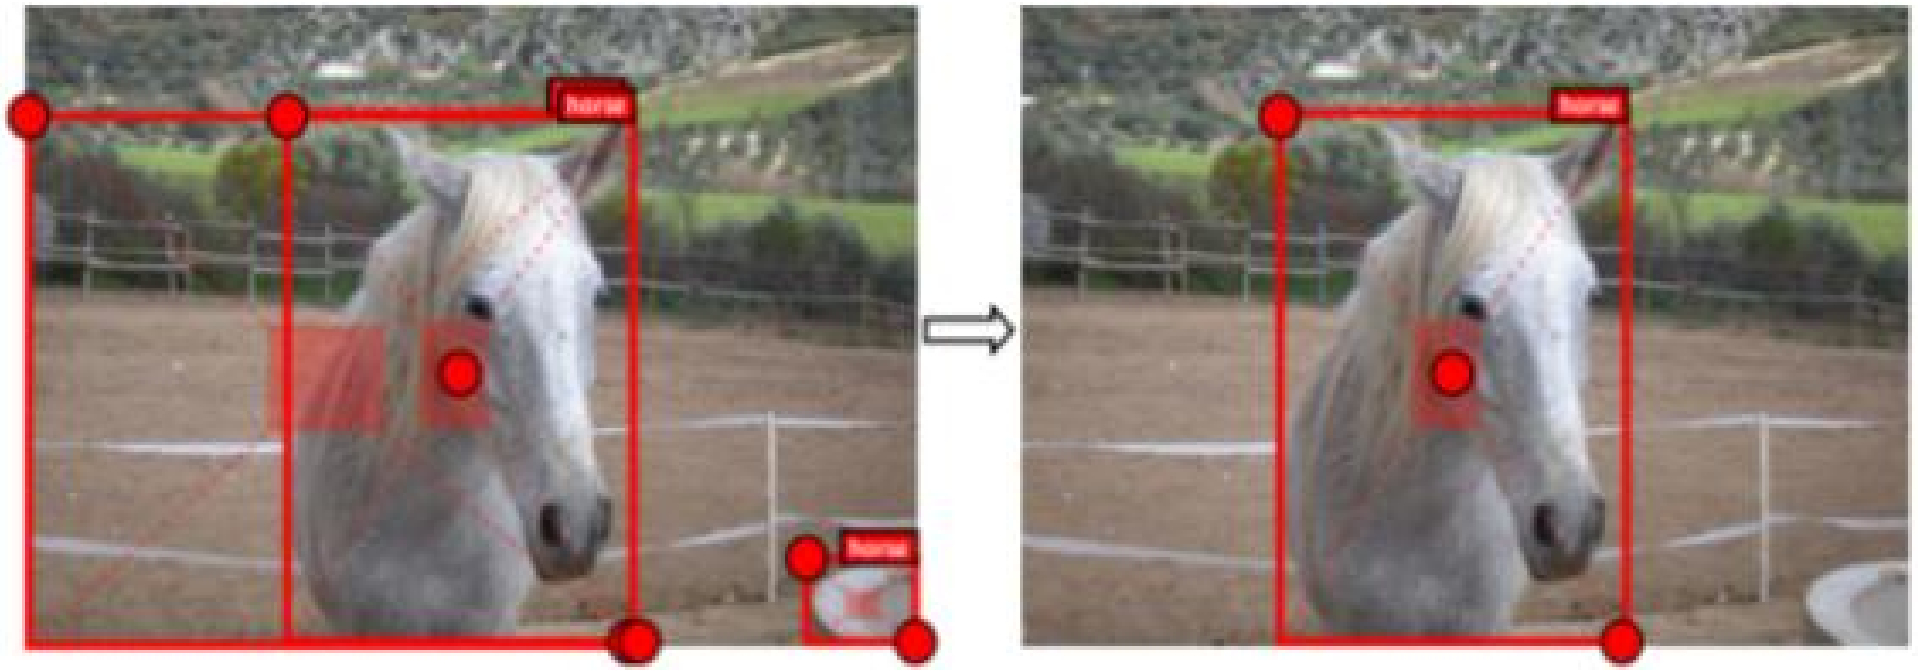


- 采用hourglass network提取特征，该网络通过串联多个hourglass module组成，每个hourglass module都是先通过一系列的降采样操作缩小输入的大小，然后通过上采样恢复到输入图像大小
- hourglass module后会有两个输出分支模块，分别表示左上角点预测分支和右下角点预测分支
- 每个分支模块包含一个corner pooling层和3个输出：heatmaps、embeddings和offsets
  a) heatmaps输出预测的角点信息
  b) embeddings用来对预测的corner点做group，找到属于同一个目标的左上角和右下角角点
  c) Offsets基于输入图像中的点映射到特征图时的量化误差，对预测框做微调

CenterNet

Anchor-free方法

用成对角点+中心点预测目标，进一步提升鲁棒性



在CornerNet的基础上，CenterNet将检测每个目标物看作是预测一组三个关键点（增加一个关键点来探索proposal中间区域的信息）而不是一对关键点，提供了更多的监督信息，从而提高了准确率及召回率。

Duan, Kaiwen, Bai, Song, Xie, Lingxi, et al. CenterNet: Keypoint Triplets for Object Detection. CVPR 2019

小结

数风流人物，还看今朝

基于卷积的目标检测

- 网络结构
  - 结构设计：问题形式化
  - 卷积：提取特征
  - 检测：全连接分类和坐标回归
- Anchor　　anchor free



Kaiming He

Associate Professor, EECS, MIT
Verified email at mit.edu - Homepage
Computer Vision　Machine Learning

2009年：研究生二年级

Cited by		VIEW ALL
	All	Since 2021
Citations	879318	692560
h-index	77	73
i10-index	94	93



Xiangyu Zhang　2019年：28岁

Co-founder & Chief Scientist of StepFun
Verified email at stepfun.com
Neural Network Architectures　Efficient Deep Learning　Computer Vision

Cited by		VIEW ALL
	All	Since 2021
Citations	476567	376447
h-index	81	80
i10-index	116	116



Shaoqing Ren

USTC & NIO
Verified email at nio.com - Homepage
Computer Vision　Deep Learning　Autonomous Driving　Artificial Intelligence

2018年：亚洲30岁以下杰出青年

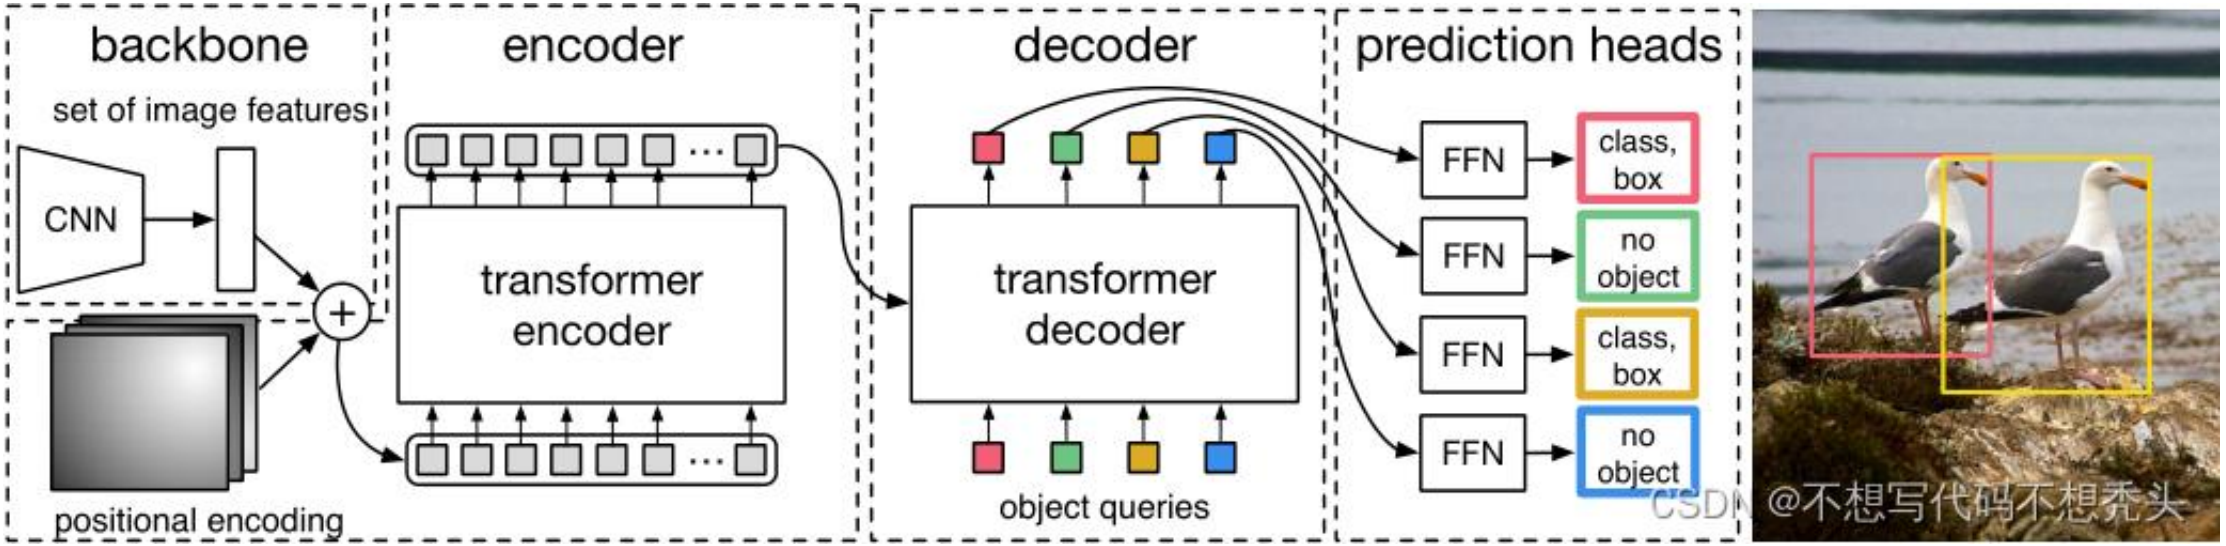
Cited by		VIEW ALL
	All	Since 2021
Citations	533241	408247
h-index	28	26
i10-index	32	31

Part 5

基于Transformer的检测方法

DETR

基于Transformer的目标检测方法



图中CNN代表图像特征编码的backbone，transformer的后面的输出就是最终预测的结果集合，假设固定为100个预测结果也就说网络输出就是100×4（框中心坐标与对应原图的长宽比例）和100×(C+1)两个tensor，分别对应框的预测和类别的预测，C表示总共的类别数,+1是背景类。

预设了100个object queries输入到decoder，去学习目标预测

DETR

基于Transformer的目标检测器

- ✓ 与之前的目标检测系统相比，DETR 的架构有根本上的改变。这是第一个将 Transformer 成功整合为检测 pipeline 的目标检测框架
- ✓ 没有NMS后处理步骤、真正的没有anchor的端到端方法
- ✓ 在性能上，DETR 可以媲美当前的 SOTA 方法，但架构得到了极大简化。具体来说，研究者在 COCO 目标检测数据集上将 DETR 与 Faster R-CNN 基线方法进行了对比，结果表明 DETR 在大型目标上的检测性能优于 Faster R-CNN。

- **特点：**

  1. encoder由多个Transformer unit组成，每个中主要包括一个多头注意力层和一个前馈神经网络层

  2. decoder包含了自注意力和交叉注意力层

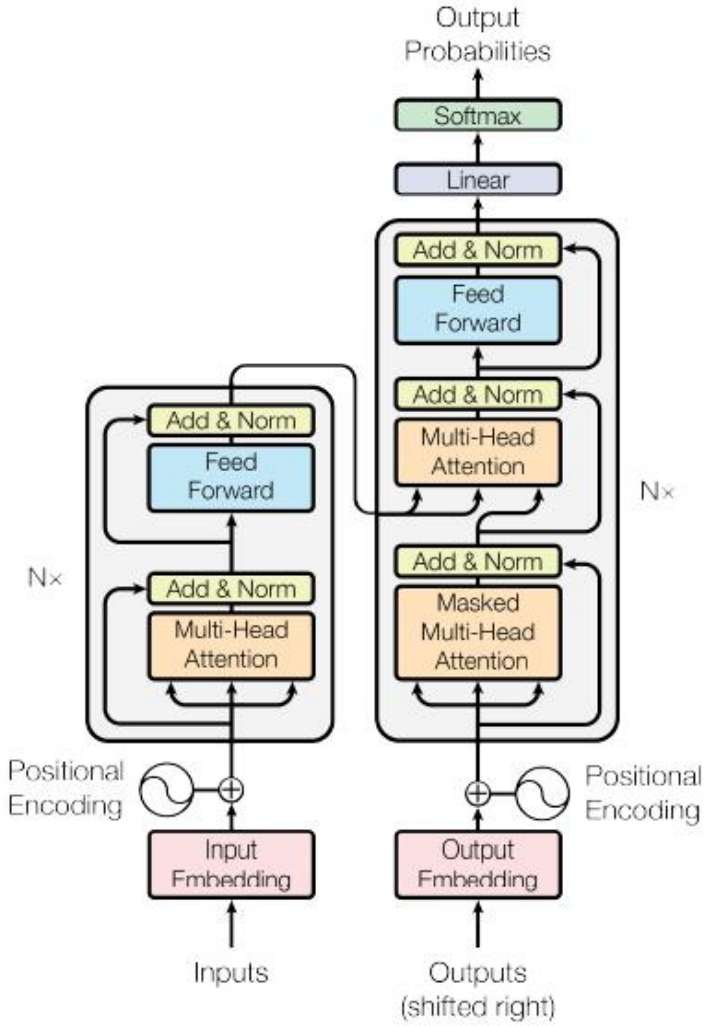


Figure 1: The Transformer - model architecture.

Carion N , Massa F , Synnaeve G , et al. End-to-End Object Detection with Transformers[J]. 2020.

Deformable-DETR

背景

- 相比于其它的目标检测模型，DETR需要更多的迭代次数才能完成收敛

学习稀疏的空间位置，采用可变形卷积的思想来学习稀疏的空间位置信息，并与Transformer强大的关系建模能力进行结合

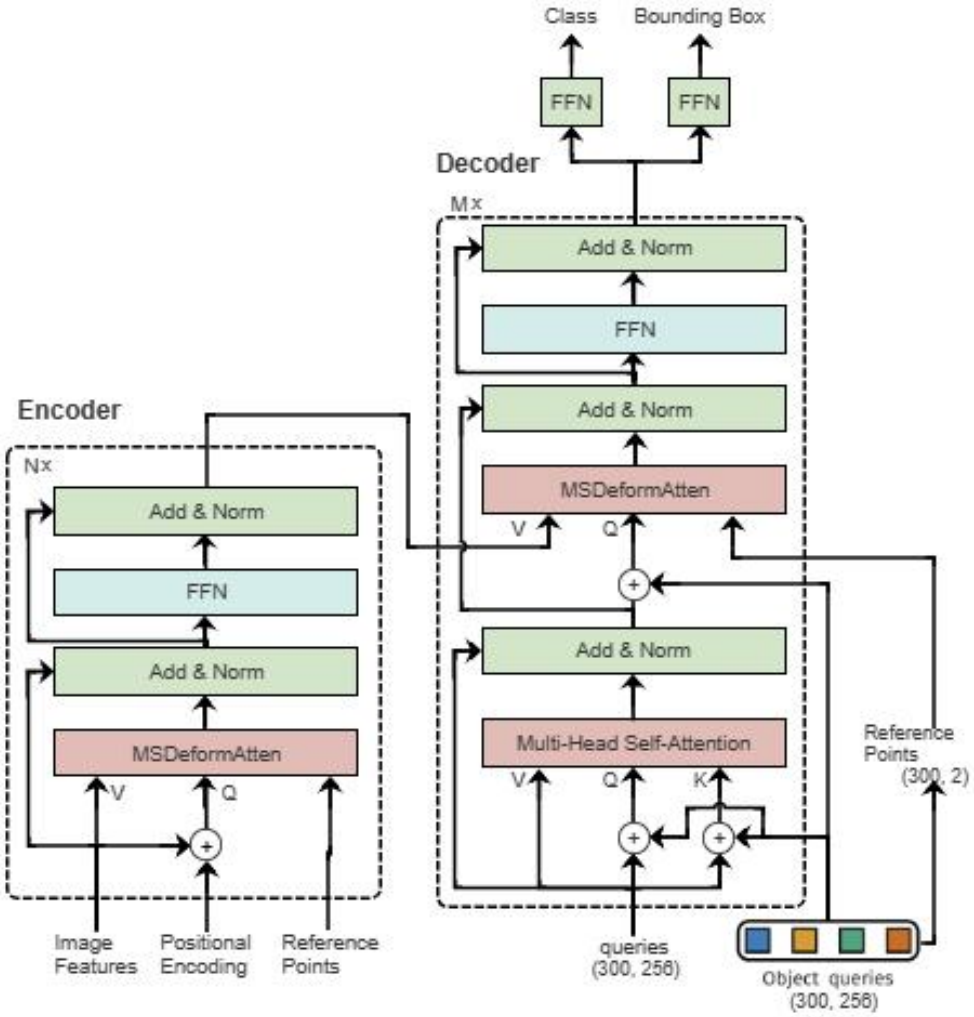
- DETR难以检测小目标物体

多尺度采样

Deformable-DETR

创新之处

- query的数目由100变成了300。
- Deformable Attention替换了原始的Attention，降低了计算复杂度。
- 最终Bounding Box预测的是物体与一系列reference point（参考点）之间的偏移量，而不是直接预测物体的绝对坐标，降低了预测难度。
- 编码器的输入是多尺度特征，提高了检测小物体的能力。



Deformable-DETR

Deformable Attention

让Attention只关注图片的部分像素，而不是全部像素，而关注哪些像素是模型自己学出来的，通过这种方式能够更快地收敛，并且由于复杂度的降低，还能够很容易的使用多尺度特征图预测。

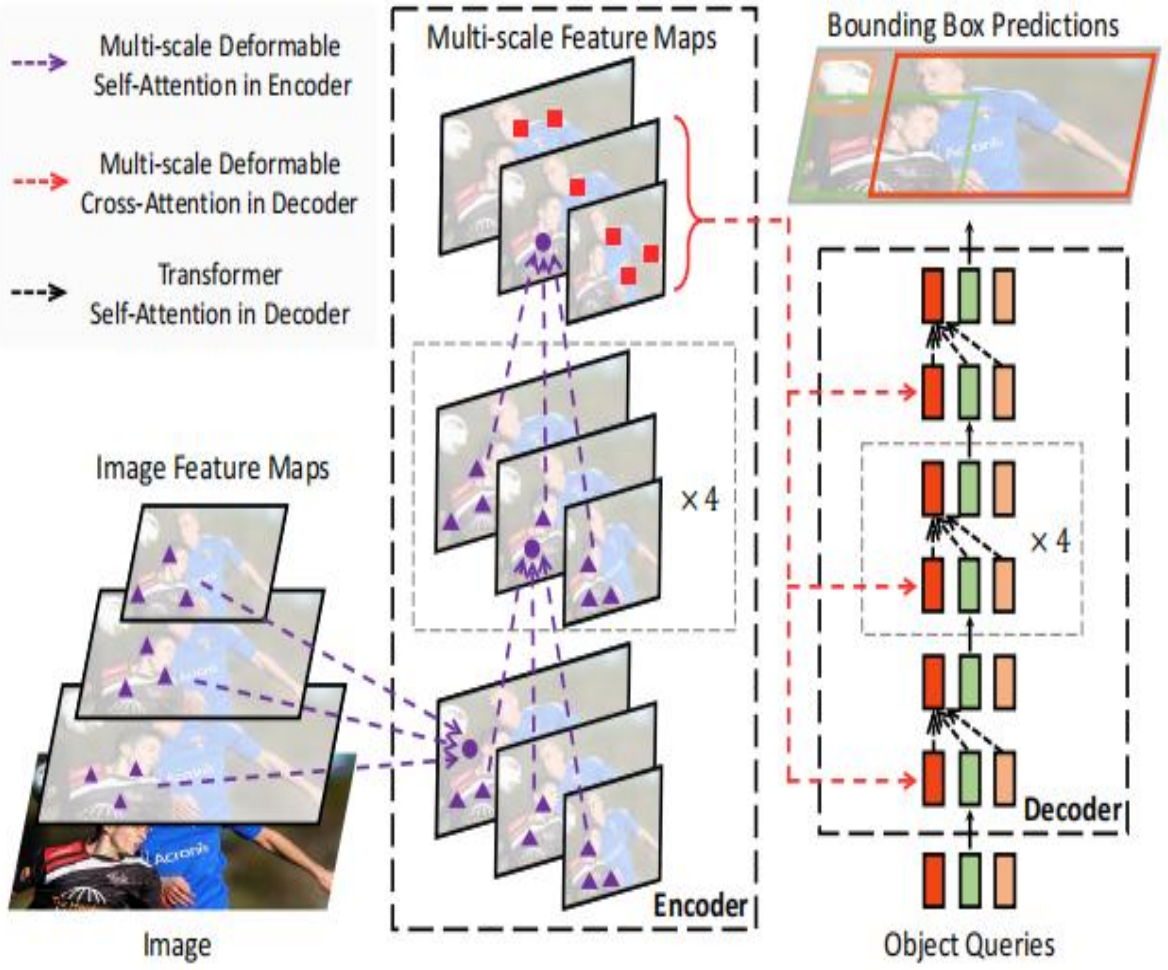
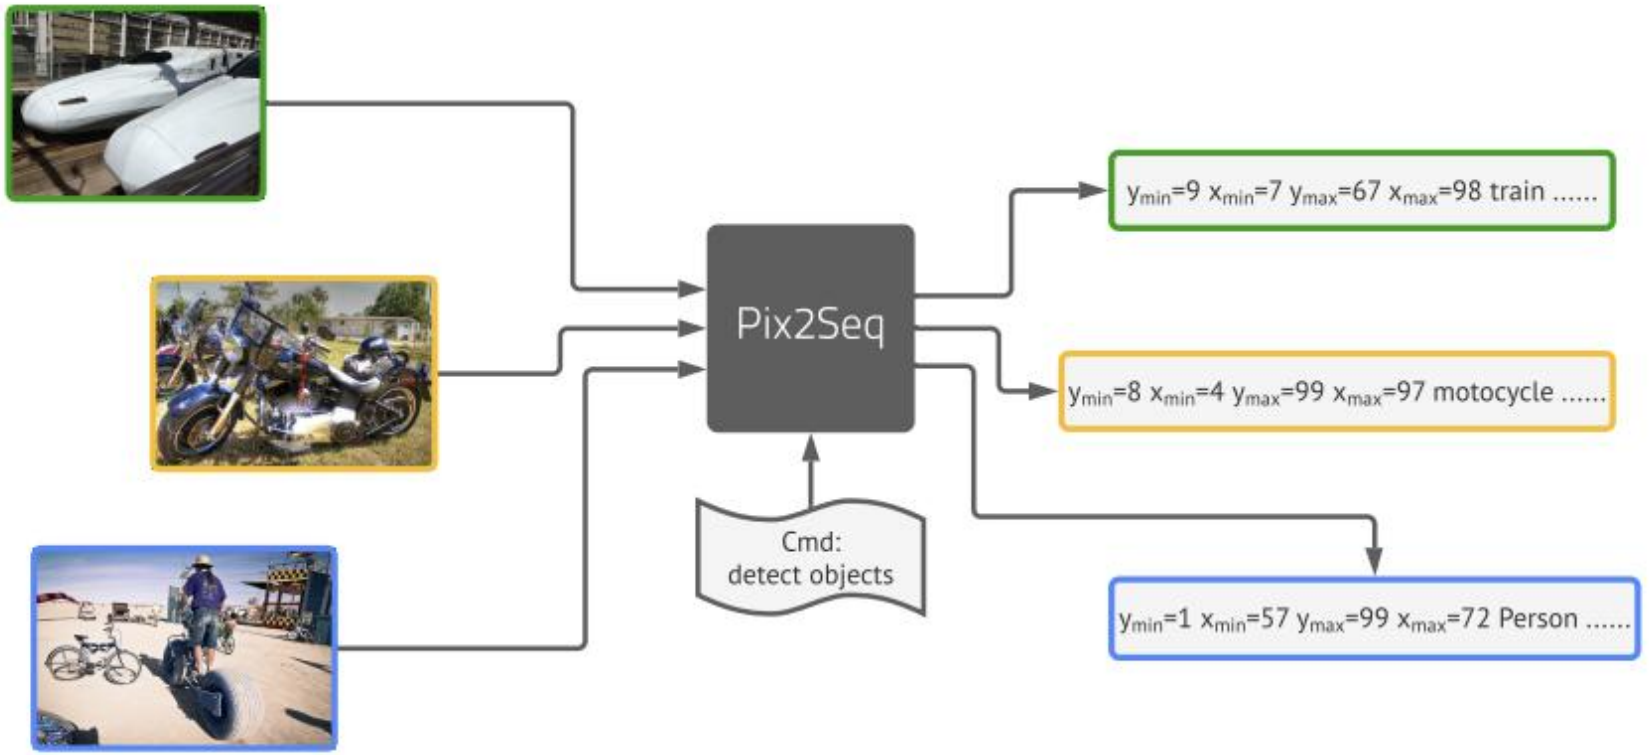


Figure 1: Illustration of the proposed Deformable DETR object detector.

Pix2Seq

用图像描述的思想逐像素点解决检测问题

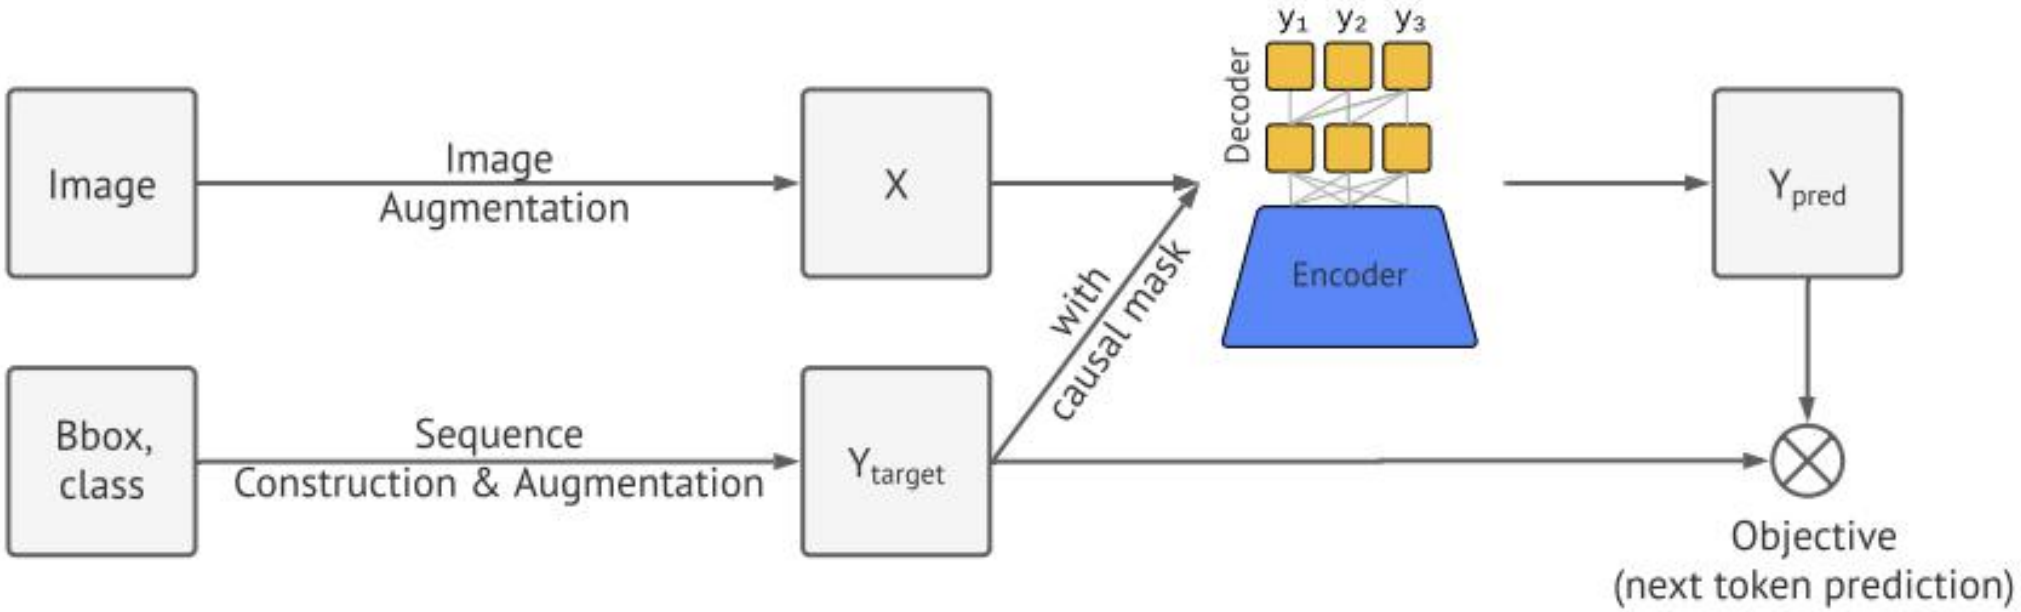
Motivation：if a neural net knows about where and what the objects are, we just need to teach it to read them out



Chen et al, Pix2seq: A Language Modeling Framework for Object Detection, ICLR 2022

Pix2Seq

用图像描述的思想逐像素点解决检测问题



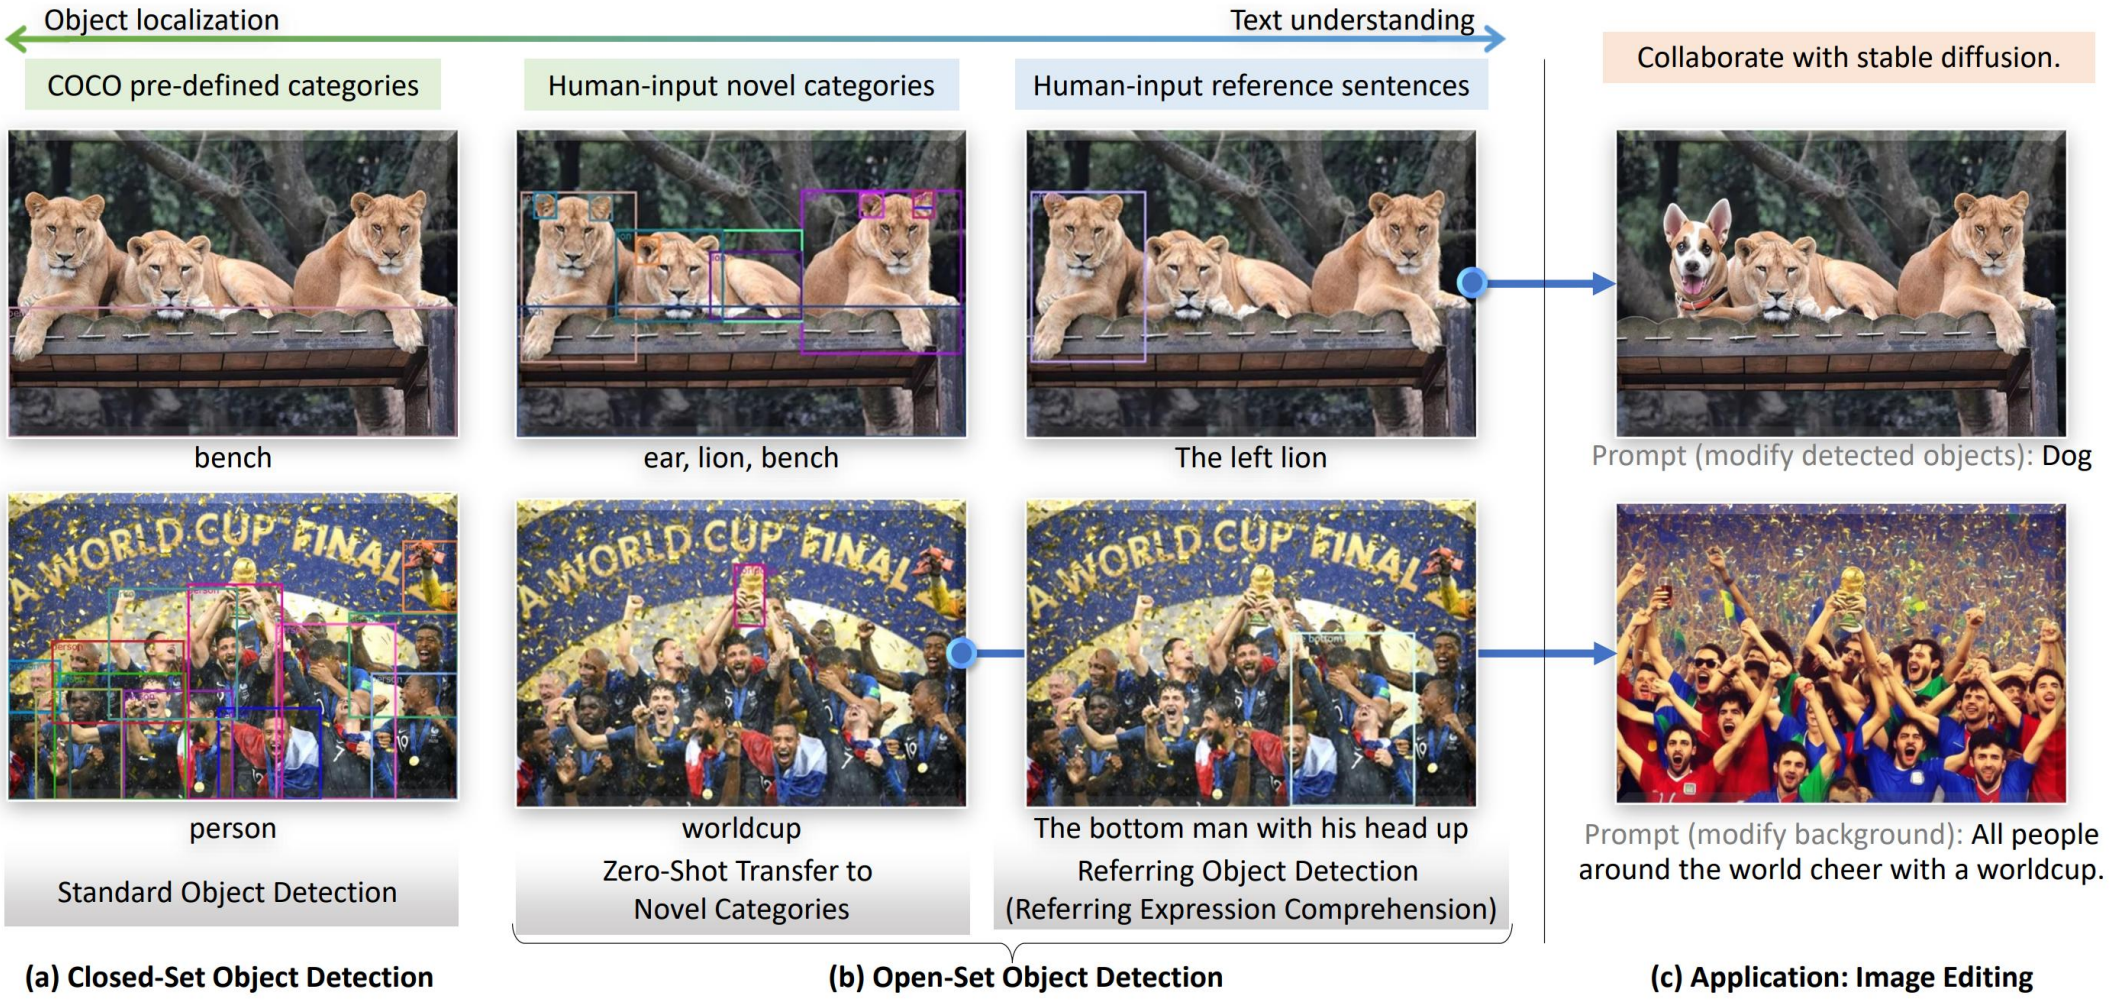
每个目标表示为：$[y_{min}, x_{min}, y_{max}, x_{max}, c]$，每个变量都归一化到整数

把所需要回归的目标框的位置和类别量化为整数，并将其拼接成一个序列，最终将该序列视为需要描述的句子，并通过自回归模型来预测该句子。与其他目标检测模型相比，Pix2Seq没有任何手工设计组件，且损失仅有分类的交叉熵损失，结构简洁。

Chen et al, Pix2seq: A Language Modeling Framework for Object Detection, ICLR 2022

开放集目标检测器

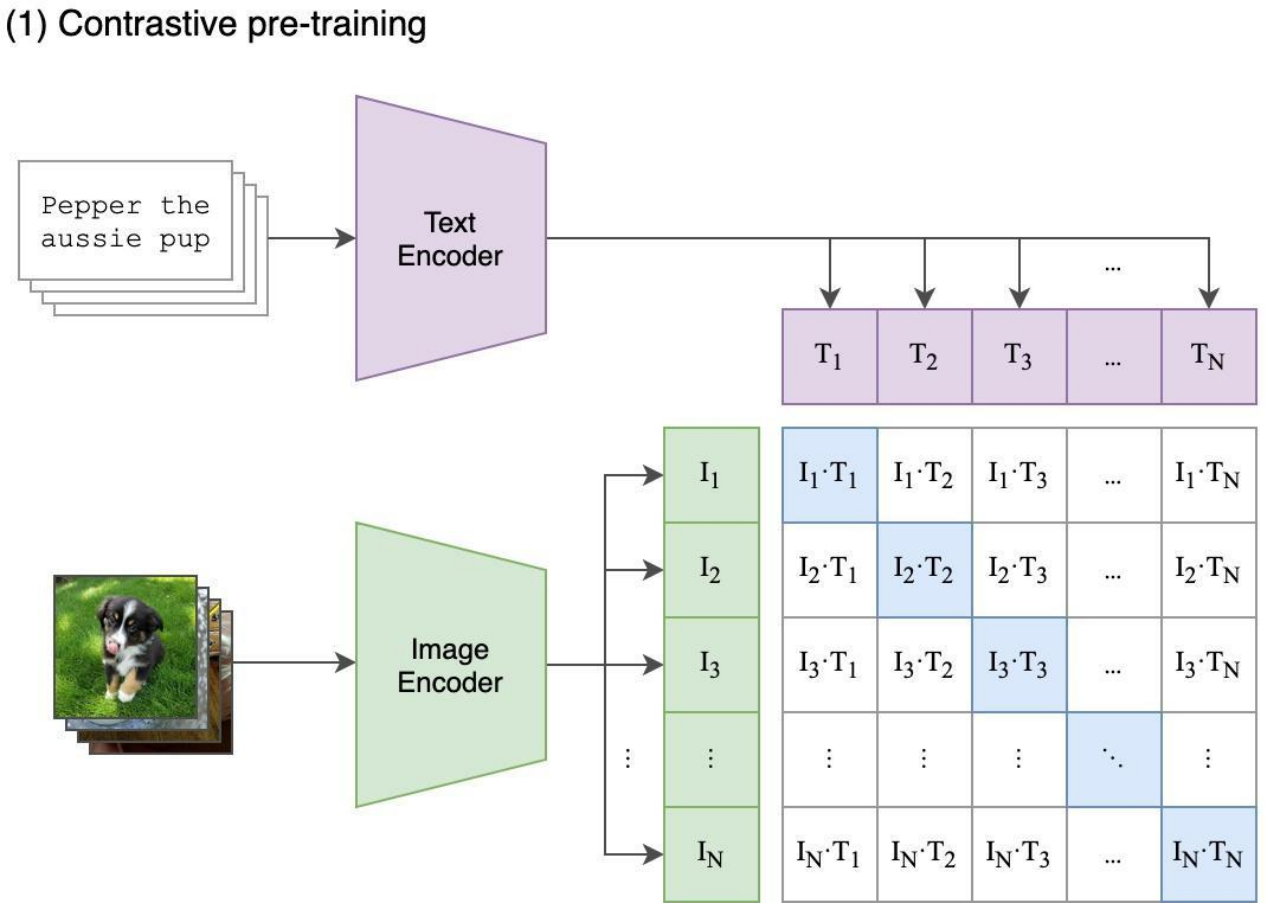
定义

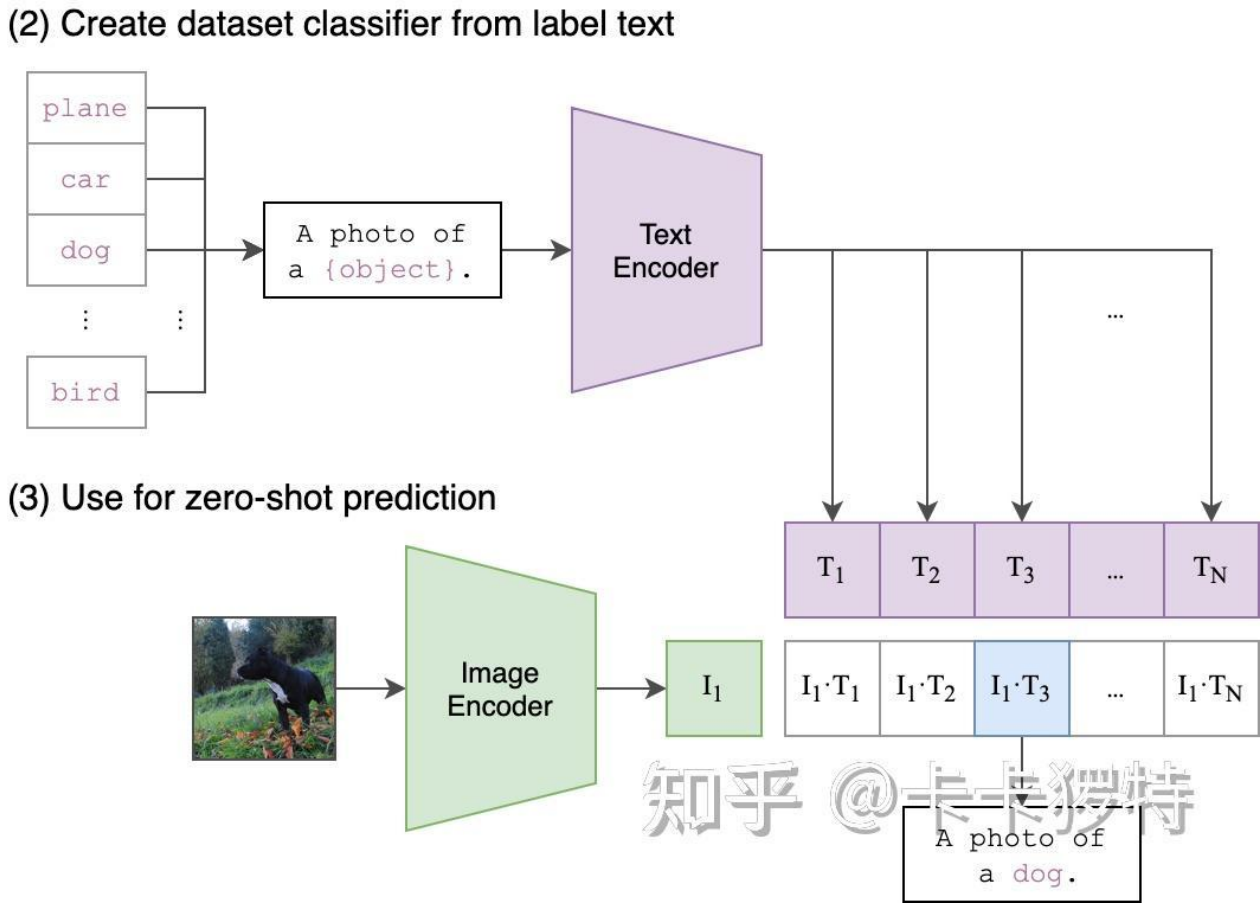


Liu et al, Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection, ECCV 2024

开放集目标检测器

CLIP：对比图像-文本预训练模型

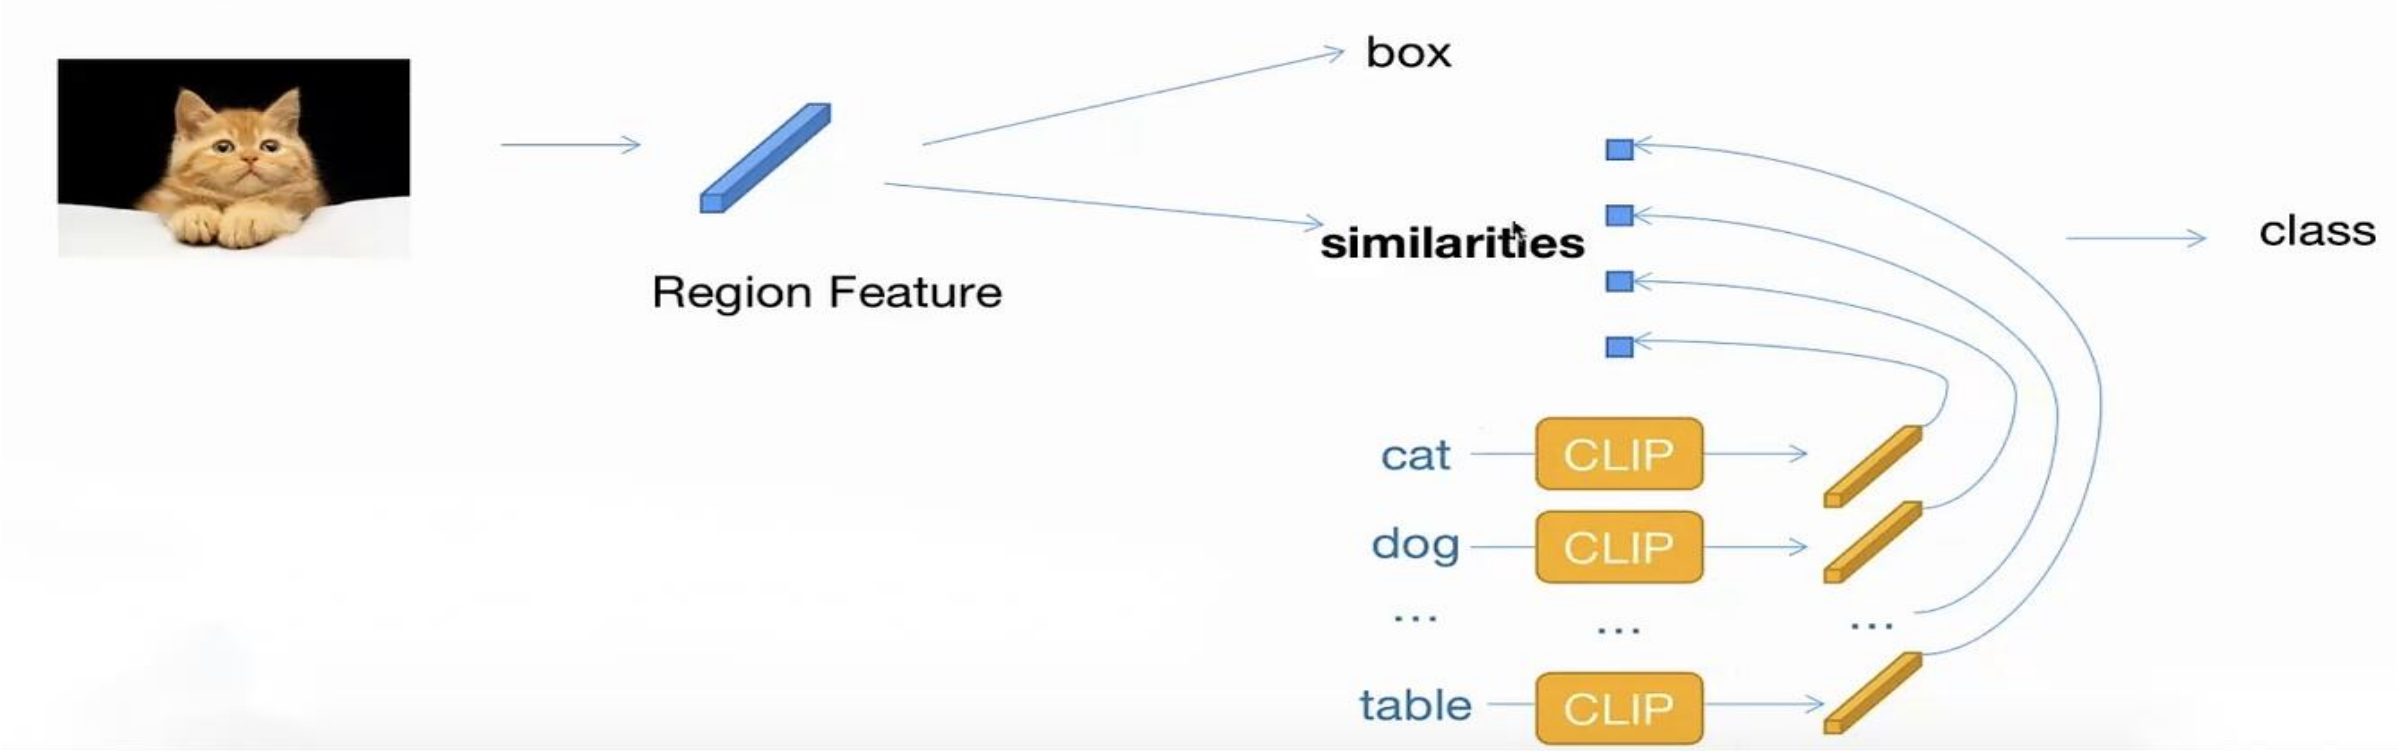




知乎 @卡卡狗特

开放集目标检测器

常见做法



Grounding DINO

网络结构

- 在目标检测器DINO的基础上，增加了文本特征提取模块。并分别在编码器和解码器部分，通过交叉注意力对文本特征和图像特征进行交互。

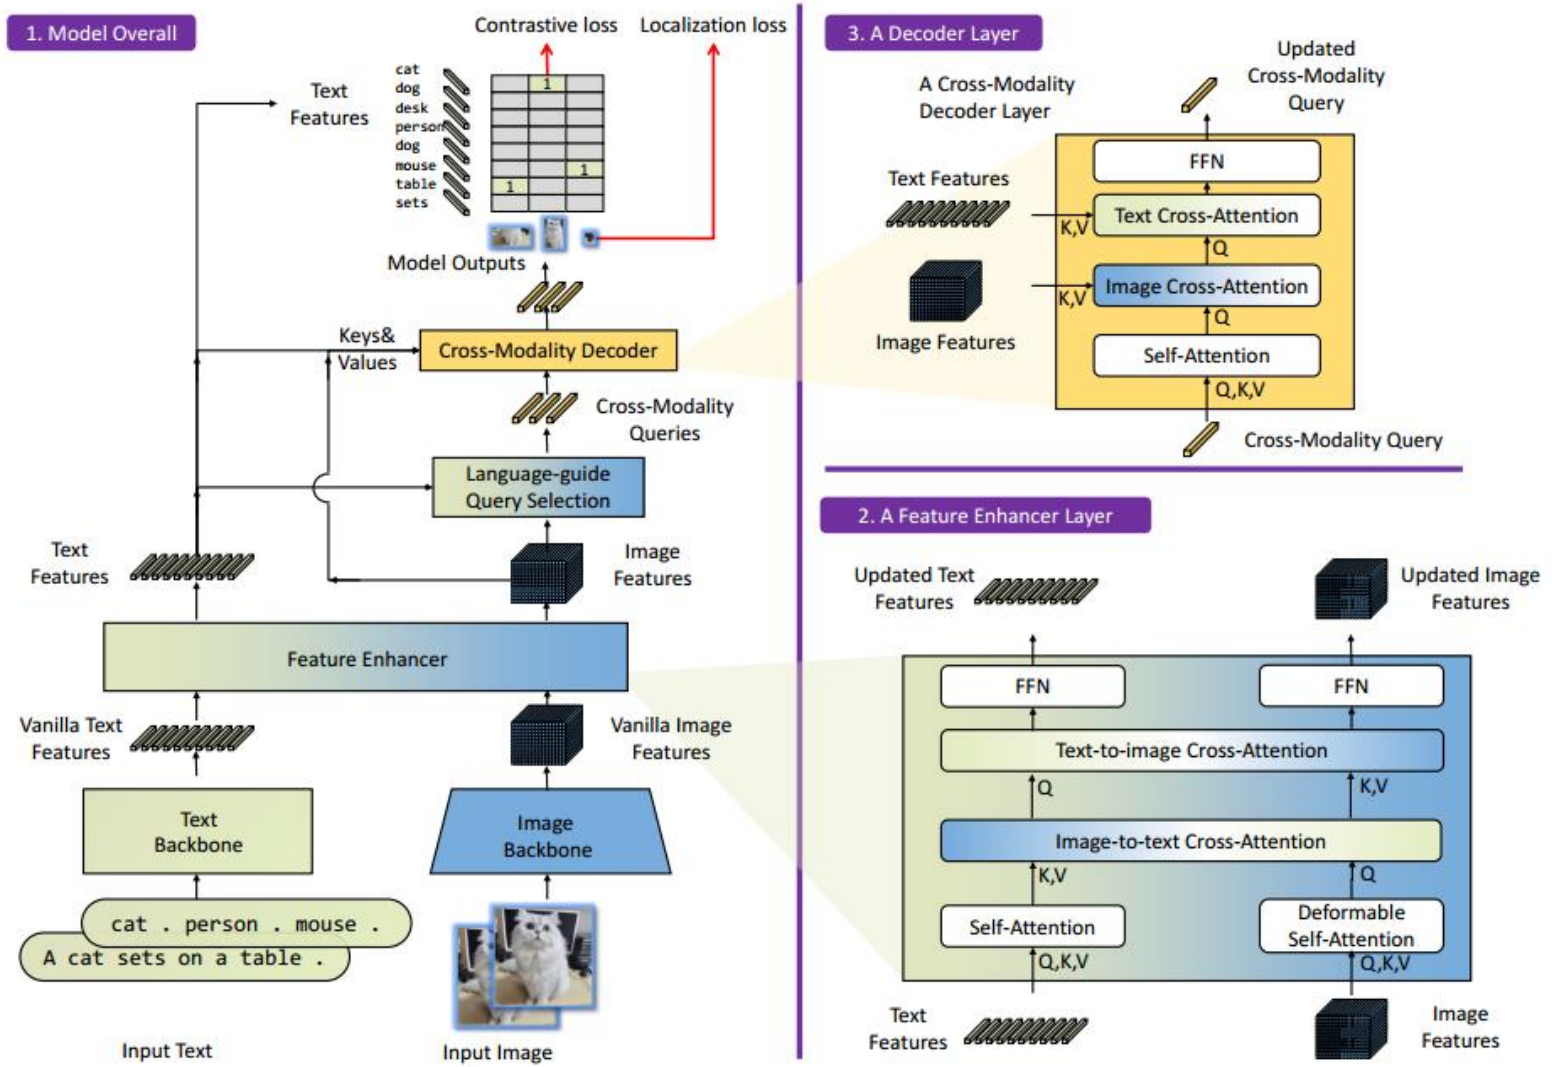


Figure 3. The framework of Grounding DINO. We present the overall framework, a feature enhancer layer, and a decoder layer in block 1, block 2, and block 3, respectively.

Part 6

目标检测的新趋势：实时、开放与可提示

目标检测正在发生什么变化

类别集合、输入方式和输出任务都在变得开放

实时 DETR

Transformer 检测器进入实时场景，形成 YOLO 之外的工程路线。

开放词汇与开放世界

模型根据临时指定的概念检测目标，并开始发现词表之外的未知物体。

通用视觉定位

检测、短语定位、分割和跟踪逐渐共享模型，通过文本或图像提示指定目标。

当类别集合、输入方式和输出任务都不再固定时，“目标检测器”的边界在哪里？

RT-DETR：DETR 进入实时检测

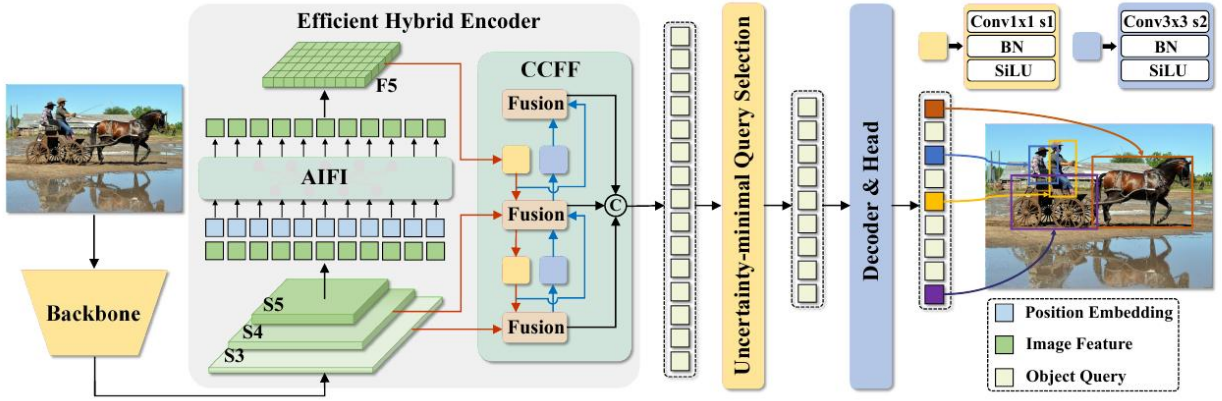
端到端检测不再只属于高计算量模型

高效混合编码器分离同尺度交互与跨尺度融合

选择不确定性较低的特征作为初始 queries

保持一对一匹配，不需要 anchor 和 NMS

调整 decoder 层数即可改变速度，无需重新训练



RT-DETR-R50：53.1 COCO AP，108 FPS

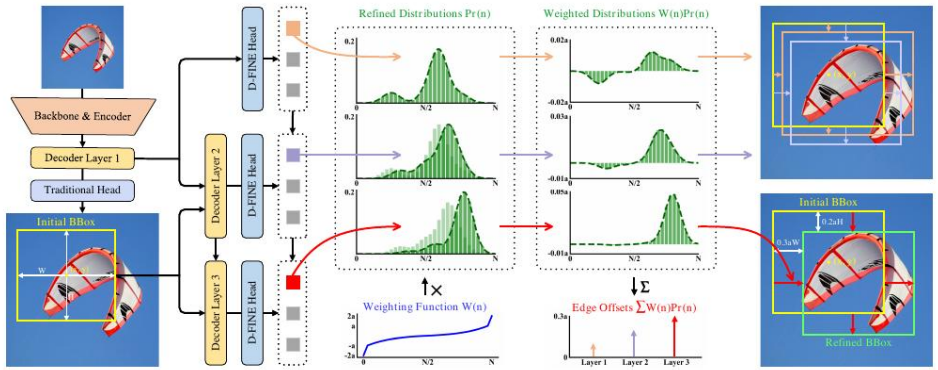
论文设置：NVIDIA T4，TensorRT FP16；实际速度取决于输入尺寸、硬件和部署框架。

Zhao et al., DETRs Beat YOLOs on Real-time Object Detection, CVPR 2024

D-FINE 与 DEIM：实时检测不只看网络结构

定位表示和训练监督开始成为竞争重点

D-FINE：边界框分布逐层细化

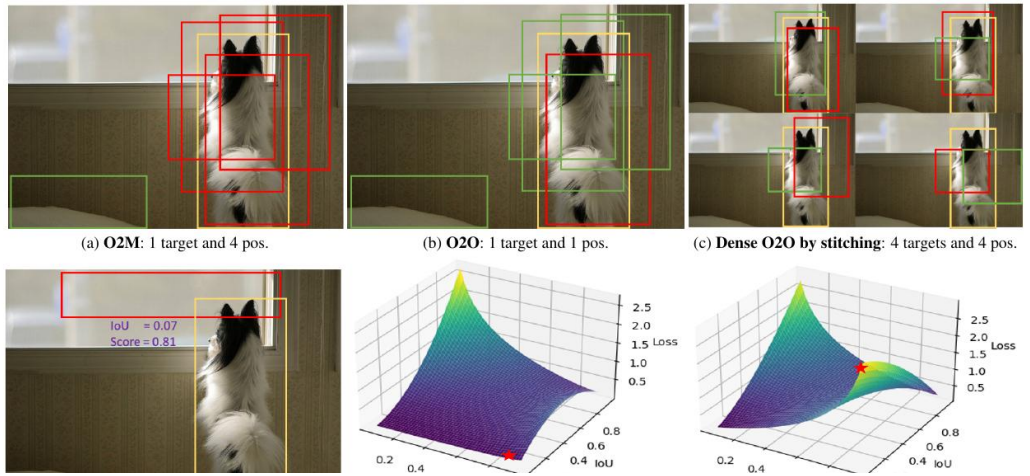


离散概率分布表示边界位置

decoder 每层继续修正分布

自蒸馏传递深层定位知识

DEIM：更密集的一对一匹配



数据增强产生额外目标

Dense O2O 增加正样本

Matchability-Aware Loss 抑制低质量匹配

Peng et al., D-FINE, ICLR 2025；Huang et al., DEIM, CVPR 2025

Grounding DINO 1.5：规模化与边缘部署

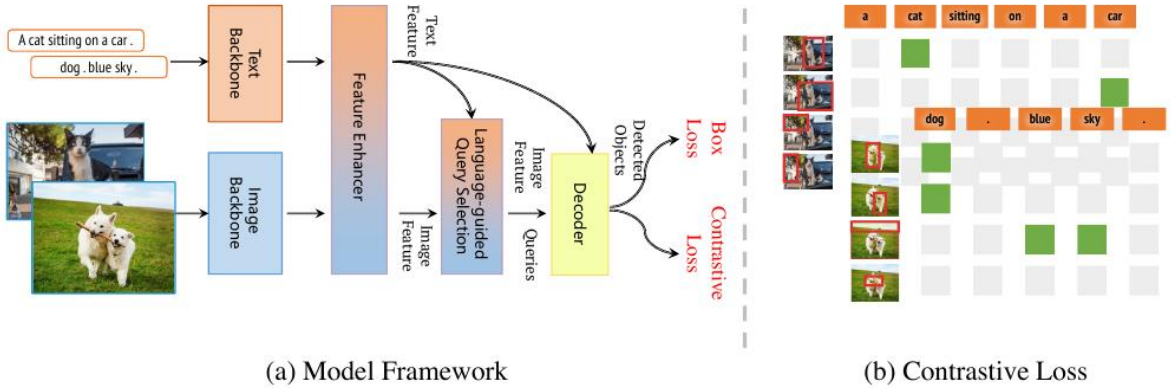
开放检测同时追求语义覆盖和部署效率

Pro

更强的视觉骨干网络

超过 2000 万张 grounding 标注图像

提升长尾类别和未见类别泛化



(a) Model Framework (b) Contrastive Loss

Edge

减少参与计算的特征尺度

优化推理结构

面向边缘设备和实时应用

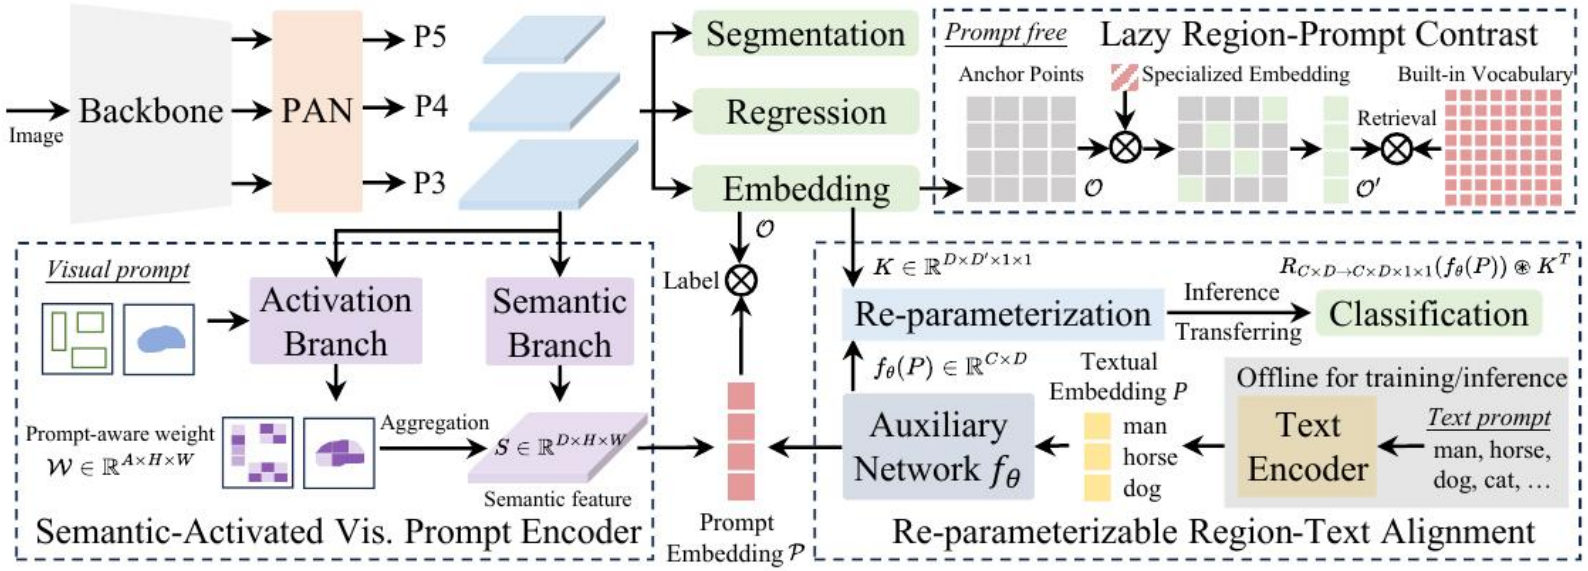
Edge：75.2 FPS，同时保留零样本检测能力

论文设置：TensorRT 优化。

Ren et al., Grounding DINO 1.5: Advance the “Edge” of Open-Set Object Detection, 2024

YOLOE：提示不再只有文本

文本、视觉示例和内置词表共享实时检测框架



文本提示

输入类别名或短语，由 RepRTA 对齐区域与文本。

视觉提示

框出示例区域，由 SAVPE 寻找外观或语义相似目标。

无显式提示

通过 LRPC 和内置大词表识别图像中的多类目标。

Wang et al., YOLOE: Real-Time Seeing Anything, ICCV 2025

开放词汇不等于开放世界

一个扩展“能说出的类别”，一个处理“还没有名字的物体”

开放词汇目标检测 OVD

用户知道要找什么，但该类别可能没有出现在检测训练集中。

- 文本概念对应检测框
- 支持训练类别之外的概念
- 输出类别与置信度

例：请寻找配送机器人

开放世界目标检测 OWOD

系统还不知道新物体叫什么，但必须先发现这里存在未知目标。

- 识别已知类别
- 发现并标记未知物体
- 增量学习新类别并减少遗忘

例：发现从未见过的移动物体

OW-OVD：结合未知发现与语言泛化

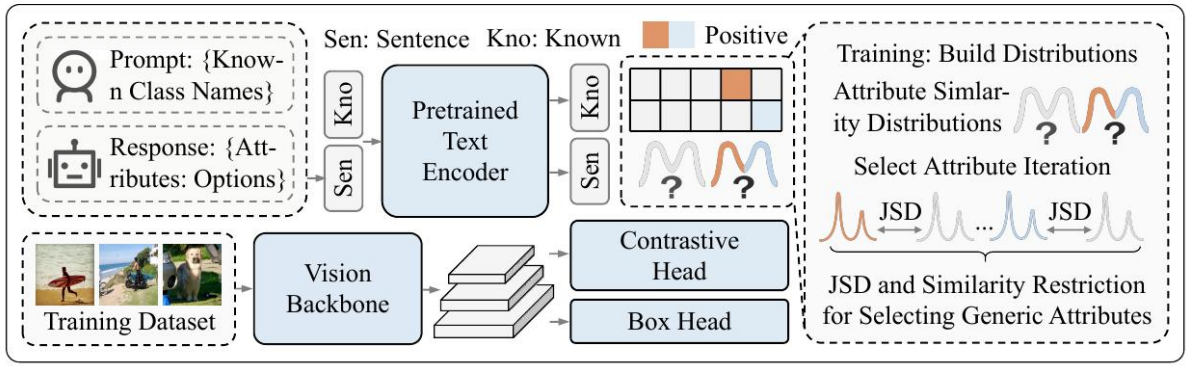
从标准开放词汇检测器出发，估计区域属于未知类的可能性

使用视觉属性描述物体，而不只依赖固定类别名

Visual Similarity Attribute Selection 选择可泛化属性

Hybrid Attribute-Uncertainty Fusion 结合属性相似度与类别不确定性

保留标准开放词汇检测的推理过程



未知目标判断可利用颜色、形状、材质、组成部分及其与已知类别的视觉关系。

论文报告：U-Recall +15.3，未知类别 U-mAP +15.5。

Xi et al., OW-OVD: Unified Open World and Open Vocabulary Object Detection, CVPR 2025

检测正在成为通用视觉模型的一种输出

Florence-2 用提示和统一序列表示多种视觉任务

传统检测器

图像 → 类别与边界框

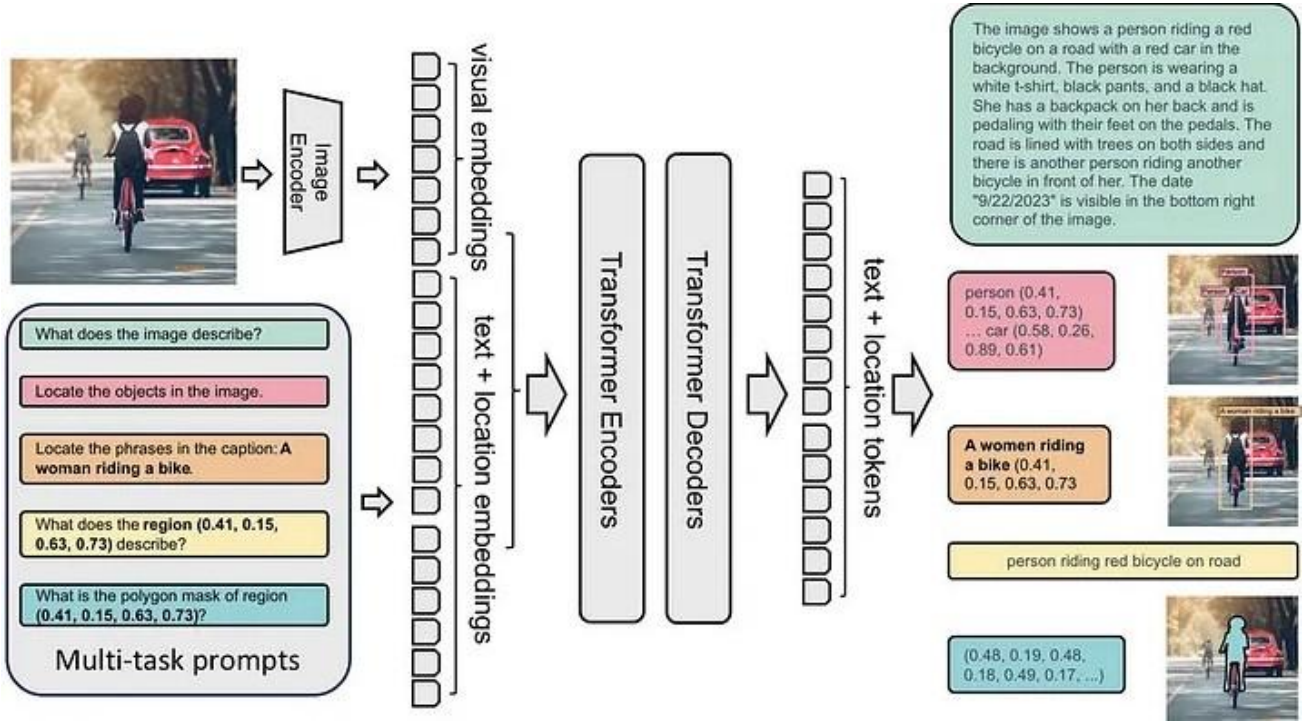
Florence-2

图像描述与 OCR

目标检测与短语定位

区域描述与分割

边界框位置 token 与文字 token 统一生成



FLD-5B：1.26 亿张图像，54 亿条视觉标注

Xiao et al., Florence-2: Advancing a Unified Representation for a Variety of Vision Tasks, 2023

小结

目标检测正在从封闭类别的框预测走向开放环境中的通用目标定位

框怎么预测?	从 anchor 和坐标回归，发展到 object queries 与分布细化
结果怎么去重?	从 NMS 后处理，发展到一对一匹配的端到端检测
类别从哪里来?	从固定类别表，发展到语言提示、视觉示例和内部大词表
遇到未知物体怎么办?	从当作背景，发展到未知目标发现和持续学习

速度和精度仍然重要，理解提示、发现未知目标，以及与分割和跟踪协同正在成为新的研究重点。

THANKS